

中国石油大学（北京）
2025— 2026 学年春季学期

《Hadoop 大数据应用》 结课报告

题 目：基于 Hadoop/MapReduce+Spark 的
离线电影推荐系统

小组成员： 陈永睿
郑 智
胡林森

成 绩：

中国石油大学（北京）克拉玛依校区

2026 年 4 月 29 日

撰写说明：

1. 为了提高学生的大数据存储和分析的应用能力和实践水平，客观考察学生的大数据分析能力，以小组任务完成一个大数据存储和分析应用案例。小组成员自行组合，每组人数 3 人。不够 3 人或者无法自行组合，由老师安排。
2. 项目内容包括数据收集、数据预处理、数据存储、数据分析和结果展示。
3. 数据收集可以是公开的数据集或者模拟数据，体现一定的数据量，数据预处理包括确保数据的一致性，数据分析包括数据分析统计，结果展示包括报表或者可视化仪表盘等。
4. 任务选题自定，体现用户对数据挖掘的需求，数据存储和分析使用 HDFS 和 Mapreduce 框架。
5. 任务体现一定工作量，体现团队合作精神，明确每个成员的分工和贡献。
6. 撰写体例参照目录。
7. 报告需要提交电子版和打印版，提交时间为结课时间一周内。
8. 报告成绩评定结合小组成绩和个人成绩。小组成绩是师生按照 8:2 权重，对小组汇报的报告工作成果进行打分。个人成绩根据小组分数，按照贡献度进行成员内部分配。例如，某小组成绩为 80，该小组的成员总分为 $80 \times 3 = 240$ ，成员 ABCD 根据贡献分配 240 分，个人分不超 100 分。
9. 严禁抄袭，一经发现，报告为 0 分。

注：依据参与度、合作度和贡献度，报告个人贡献。各位在提交报告时，只需填写成员和任务贡献%这一列，不但填自己的贡献，还要填小组其他成员的贡献，且小组内各个成员取得一致。

注

组号	成员	任务贡献%	个人分数	备注
6	A	30%	72	≤ 100
	B	30%	72	≤ 100
	C	40%	96	≤ 100
总计	80×3	100%	240	小组得分 80

目 录

一、选题与组内任务分配	4
二、需求分析	5
2.1 背景与目标	5
2.2 数据集说明	5
2.3 功能需求	5
三、设计思路与实现方法	6
3.1 整体架构	6
3.2 数据预处理 (ml100k_build_csv.py)	6
3.3 基于 hiveql 的数据统计与冷启动支持	7
3.4 MapReduce 协同过滤流水线	8
3.5 Spark ML 训练与融合	9
四、结果展示和关键代码分析	9
4.1 探索性数据分析 (EDA)	9
4.1.1 整体评分分布	9
4.1.2 用户维度评分分析	10
4.1.3 性别 × 评分分布	10
4.1.4 电影维度评分分析	11
4.1.5 类型 × 平均评分分析	11
4.2 MapReduce 流水线产出	12
4.3 Spark 模型评估结果	12
4.3.1 训练集 / 测试集用户分布	12
4.3.2 分类器验证集 AUC 对比	13
4.3.3 融合权重 α 扫描 (验证集)	14
4.3.4 CF 与融合对比 (测试集 Global hit@10)	14
4.3.5 Top-10 推荐品类分布 (多样性截断后)	15
4.3.6 测试集指标汇总	16
4.4 运行时间统计	17
五、团队沟通记录	17
六、总结个人贡献与存在问题	18
6.1 项目总结	18
6.2 存在问题与改进方向	19
6.3 个人贡献总结	19

一、选题与组内任务分配

MovieLens 100K 是由明尼苏达大学 GroupLens 实验室发布的经典推荐系统基准数据集，包含 943 名用户对 1682 部电影的 100,000 条评分记录（评分范围 1 - 5 分），并附有用户人口统计信息（年龄、性别、职业）及电影类型标签。数据集规模适中、标注完整、划分规范，是研究协同过滤与混合推荐方法的理想实验平台。

本研究的核心问题是：在隐式反馈场景下，如何融合协同过滤与分类模型，为用户生成高质量的个性化电影推荐列表。

系统将评分 ≥ 4 的记录视为正样本，构造隐式偏好信号，并以此驱动后续的候选召回阶段。

选题具有以下三方面意义：

第一，工程实践价值。

本系统完整实现了从 Hadoop MapReduce 数据预处理、HDFS 存储、Item-CF 候选召回，到 Spark 特征工程与 GBT/LR/RF 分类排序的全链路推荐管道，覆盖大数据课程的核心技术栈。

第二，方法对比价值。

通过对 LR、GBT、随机森林三种分类器在验证集 AUC 上的系统对比，以及融合权重 α 的网格搜索，可以定量分析协同过滤信号与用户/商品画像特征的互补效果。

第三，评估严谨性。

研究采用时序留出（time_last）作为主评估协议，同时支持 LOO 与官方 u1 - u5 固定切分，从 Globalhit@10、StrictPrecision@10、NDCG@10 及分层分析（性别、活跃度、主导品类）多维度衡量推荐质量，具备较强的可复现性与可比较性。

组号	成员	任务贡献%
	陈永睿	39%
	郑 智	33%
	胡林森	28%
总计		

二、需求分析

2.1 背景与目标

随着互联网影视内容的爆发式增长，用户面临严重的‘信息过载’问题——海量电影中难以快速定位符合个人口味的内容。推荐系统通过挖掘用户历史行为，主动推送个性化内容，已成为流媒体平台的核心基础设施。

本项目基于 MovieLens 100K 数据集，构建一套完整的离线推荐实验流水线，目标如下：

- 利用 HDFS 进行大规模数据分布式存储与管理；
- 基于 Map Reduce Streaming 实现 Item-CF（基于物品的协同过滤）候选生成；
- 借助 Spark ML 训练逻辑回归（LR）、梯度提升树（GBT）、随机森林（RF）等分类模型，对候选集打分；
- 通过 α 融合策略将 CF 分数与 ML 模型概率结合，提升推荐命中率；
- 输出多维度评估指标（AUC、Precision @K、Recall @K、NDCG@K）及可视化图表。

2.2 数据集说明

MovieLens 100K 由 GroupLens 实验室发布，包含 943 名用户对 1,682 部电影的 100,000 条评分记录，评分范围 1–5 分（整数）。主要文件包括：

文件	格式	说明
u.data	user_id;item_id;rating;ts	100,000 条评分，含时间戳
u.item	pipe 分隔, 含类型 one-hot	1,682 部电影标题与 19 个类型标志位
u.user	user_id;age;gender;occ;zip	943 名用户人口统计特征

2.3 功能需求

- 数据收集与预处理：将原始 ML100K 三个文件合并为统一 CSV，构造隐式标签（ $\text{rating} \geq 4$ 为正样本），添加时间戳供时间切分；
- 数据存储：将 CSV 上传至 HDFS，各 MR 阶段产物均存储于 HDFS 相应路径；
- Item-CF 候选生成：通过 MapReduce 计算物品共现与余弦相似度，生成 Top-N 候选；
- 特征工程与模型训练：在 Spark 中构造用户/物品 profile 特征，训练 LR/GBT/RF 三类分类器；

- 融合与排序：以验证集 AUC 为准则扫描最优融合权重 α ，输出多样性截断的 Top-10 推荐列表；
- 评估与可视化：计算 AUC、Recall@K、NDCG@K、Bootstrap CI 等指标，生成图表。

三、设计思路与实现方法

3.1 整体架构

系统采用‘数据预处理 → HDFS 存储 → MapReduce 协同过滤 → Spark ML 融合评估’的四层流水线架构，如图所示：

```
MovieLens 100K → ml100k_build_csv.py → recsys_ml100k.csv → HDFS
    ↓
    MapReduce (A1 隐式评分 → B1 共现 → B2 相似度 → CF 候选生成)
    ↓
    Spark (特征工程 → LR/GBT/RF 训练 →  $\alpha$  融合 → 排序评估)
```

3.2 数据预处理（ml100k_build_csv.py）

数据预处理脚本负责将 MovieLens 三个原始文件整合为统一的 CSV 格式，供后续 MapReduce 与 Spark 使用。核心设计如下：

标签构造：评分 ≥ 4 定义为正样本（label=1），其余为负样本（label=0），与实际‘喜欢’行为吻合；

特征对齐：提取用户特征（年龄、性别、职业）、物品特征（类型、标题长度）及行为统计（评分频次、累计支出代理）；

时间戳保留：将 u.data 中的 Unix 时间戳写入 event_ts 列，供 Spark 进行时间切分评估；

ID 规范化：user_id 前缀 U、item_id 前缀 I，避免数值 ID 在后续 join 时发生类型冲

突。

关键代码片段（ml100k_build_csv.py）：

```
# 正负样本标签构造
label = 1 if rating >= 4 else 0

# 用户活跃度代理特征
pf = uid_counts.get(uid, 1) # 历史评分次数
total_spend = uid_spend.get(uid, rating) * 88.0 # 累计消费代理

# 物品价格代理（基于历史平均评分）
price = round(iid_avg_rating.get(iid, float(rating)) * 18.0, 2)

# 时间切分所需的时间戳
row = [..., int(ts), label] # event_ts 为最后第二列
```

3.3 基于 hiveql 的数据统计与冷启动支持

为了弥补纯协同过滤在面对新物品和新用户时的“冷启动”缺陷，本系统在特征工程和流水线中引入了基于 sql 的离线统计视图。我们编写了 hive_compat.sql，利用 spark sql 执行兼容 hiveql 的聚合查询，构建了 hive_user_rollups 和 hive_item_rollups 视图。通过 compute_cat_top1.py 脚本，系统会离线计算出每个电影类别下评分最高、最热门的 top-1 代理物品（cat_top1）。当系统遇到缺乏历史行为的冷启动用户时，会利用其人口统计学特征（如年龄、性别代理均值），结合各品类的热门物品提供 baseline 推荐。这种 sql 统计与 mr 协同过滤双线并行的架构，提升了推荐系统的鲁棒性。

关键的 HiveQL 聚合代码（以物品维度为例）如下：

```
执行兼容 HiveQL 的聚合查询，提取分类并计算平均指标
CREATE OR REPLACE TEMP VIEW hive_item_rollups AS
SELECT item_id,
       First(category) AS category,
       AVG(price) AS avg_price,
       AVG(like_num) AS avg_like_num
FROM raw_events
GROUP BY item_id;
```

3.4 MapReduce 协同过滤流水线

MapReduce 阶段分为五个步骤，均使用 Hadoop Streaming 以 Python 脚本驱动：

阶段	作业名	功能	耗时（本次运行）
A1	ratings	汇总 user#item $\rightarrow$ score 隐式评分	8s
A2	item_totals	统计各物品总评分次数（供 IDF 加权）	8s
B1a/b	cooc / bla	用户级物品共现对（含品类代理 proxy）	15s + 24s = 39s
B2	item_sim item_topn	/ 余弦相似度 + Top-N 邻居筛选	12s
CF 候选	cf_candidates	生成 user, item, cf_score 候选集上传 HDFS	9s
合计			123s

B1 Reduce 关键代码（mr_bl_red.py）：为每位用户生成其历史物品两两共现对，截断至 200 个物品防止用户过活跃导致的组合爆炸：

```
def emit_pairs(items):
    items = sorted(set(items))
    if len(items) > 200:          # 截断防止复杂度爆炸
        items = items[:200]
    n = len(items)
    for a in range(n):
        for b in range(a + 1, n): # 遍历所有无序对
            i, j = items[a], items[b]
            if i > j:
                i, j = j, i
            print(f'{i}\t{j}\t1')
```

CF 候选生成（cf_gen_candidates.py）：基于 item_topn 相似邻居，为每个用户计算未交互物品的 CF 分数（取最大相似度），输出 Top-10 候选：

```
for u, items in u_items.items():
    cand = {}
    for i in items:          # 用户历史物品
        for j, sim in nbr.get(i, []): # 相似邻居
            if j in bought or j in items: # 过滤已交互
                continue
            cand[j] = max(cand.get(j, 0.0), sim) # 取最大相似度
```



```
for j, sc in sorted(cand.items(), key=lambda x: -x[1][:10]):
    print(f'{u}\t{j}\t{sc}')
```

3.5 Spark ML 训练与融合

Spark 阶段（recsys_spark.py）包括以下子模块：

- 数据切分：采用 `time_last` 协议——每用户最近一次评分作为测试集，历史记录作训练集（943 名用户全部覆盖测试与训练）；
- 负采样：在训练集上将正负样本比例控制在约 1:3，缓解样本不平衡；
- 特征工程：用户 `profile` 特征（年龄、性别、活跃度）与物品 `profile` 特征（价格、类别）汇总自训练集，不使用任何 `row-level` 泄露特征；
- 模型训练：LR / GBT / RF 在 85%/15% 的训练内部验证集（`seed=11`）上竞争，以验证集 AUC 选择最优模型；
- 融合： $\text{fused_score} = \alpha \times \text{p_buy} + (1-\alpha) \times \text{cf_norm}$ ，在验证集上扫描 $\alpha \in [0.0, 1.0]$ ，以 AUC 为准则确定最优 α ；
- 多样性截断：贪心策略限制 Top-10 中同类别物品不超过 4 个；
- 评估：计算 Strict Precision/Recall@10、Global hit@10、Recall@10(rel)、NDCG@10 及 Bootstrap 95% CI。

Spark NDCG 实现：

```
def dcg_at_k(rels, k):
    rels = np.asarray(rels, dtype=float)[:k]
    if rels.size == 0: return 0.0
    return float(np.sum(rels / np.log2(np.arange(2, rels.size + 2))))

def ndcg_at_k(rels, k):
    d = dcg_at_k(rels, k)
    ideal = np.sort(rels)[::-1]
    i = dcg_at_k(ideal, k)
    return (d / i) if i > 0 else 0.0
```


四、结果展示和关键代码分析

4.1 探索性数据分析（EDA）

4.1.1 整体评分分布

MovieLens 100K 共含 100,000 条评分记录，评分分布呈右偏态——评分 4 分最多

（34,174 条），其次为 3 分（27,145 条）和 5 分（21,201 条），1 分最少（6,110 条）。以 $\text{rating} \geq 4$ 为正样本的 label 划分下，正样本比例约为 55.4%，数据集整体偏乐观，符合用户倾向于对感兴趣内容打分的行为规律（CDF 图中虚线处对应约 45% 的累积比例）。



4.1.2 用户维度评分分析

用户活跃度呈典型长尾分布：每用户评分数中位数为 65，少数超活跃用户评分数超过 500，多数用户集中在 20–100 条之间。每用户平均评分均值为 3.59，分布接近正态，说明不同用户的评分习惯差异不显著。每用户正样本率 ($\text{rating} \geq 4$ 占比) 均值为 57.8%，整体偏高，反映用户在评分时存在‘选择偏差’——倾向于对喜欢的内容评分。




图 4-2 用户评分数分布（左）、平均评分分布（中）、正样本率分布（右）

4.1.3 性别 × 评分分布

男女用户（性别 M/F）的评分分布极为接近，均在 4 分处达到峰值。男性用户在评分 4 分处占比（约 34.7%）略高于女性（约 32.2%），女性在 5 分处占比（约 23.3%）略高于男性（约 20.7%），整体差异很小，说明性别对评分习惯的影响有限，模型中性别特征主要作为用户侧统计特征辅助泛化而非决定性因子。




图 4-3 性别 × 评分分布（归一化）

4.1.4 电影维度评分分析

电影被评次数同样呈强长尾特征，中位数仅为 27 次，而热门电影被评次数可达 400+ 次（见散点图右侧）。平均评分均值为 3.08，低于用户侧均值 3.59，说明大量冷门电影因评分人数少而平均分偏低或偏高，形成不稳定估计。热门电影散点图显示：评分次数 100 以上的电影平均评分多集中在 3.5–4.2 分区间，说明热度与口碑存在一定正相关，但并非线性。




图 4-4 电影被评次数分布（左）、平均评分分布（中）、热门电影被评次数 vs 平均评分（右）

4.1.5 类型 × 平均评分分析

按主类型统计平均评分，Film-Noir 以 4.06 分（n=1,012）位居首位，Crime、Musical、Drama 等类型均高于全局均值（3.53，红色虚线），而 Horror（3.23）、Children's（3.17）、War（2.96）、Fantasy（1.00，仅 1 条记录）等类型低于均值。Drama 样本量最大（n=27,050），是最可靠的参考类别。该分析为冷启动场景下的‘类别热门回退’策略提

供了依据——当新用户/物品缺乏个性化信号时，优先推荐 Drama、Film-Noir 等高分类别的热门影片。




图 4-5 各类型电影平均评分（含样本量）

4.2 MapReduce 流水线产出

MapReduce 共运行 9 个阶段，总耗时 123 秒（本地模式）。各阶段 HDFS 主要产物如下：

HDFS 路径	文件大小	说明
/recsys/raw.csv	10.7 MB	原始 CSV 上传至 HDFS
/recsys/ratings/part-00000	1.1 MB	A1 隐式评分 (user#item → score)
/recsys/b1a/part-00000	69.9 MB	B1a 共现对（最大阶段产物）
/recsys/item_sim/part-00000	19.8 MB	余弦相似度对
/recsys/item_topn	1.8 MB	Top-N 相似邻居（截断后）
/recsys/cf_candidates	268 KB	最终 CF 候选 (user, item, cf_score)

4.3 Spark 模型评估结果

4.3.1 训练集 / 测试集用户分布

采用 time_last 切分协议，943 名用户的最近一条评分记录作为测试样本，其余历史记录用于训练。如图所示，训练用户数与测试用户数均为 943，实现了全量用户覆盖——每位用户在训练集中至少有一条历史行为可供建模，同时在测试集中有对应的目标行为待预测，这是时序评估协议的标准设计。




图 4-6 训练集 / 测试集用户数 (time_last 切分)

4.3.2 分类器验证集 AUC 对比

在验证集（训练集内部 15% 划分）上，三个分类器的 AUC 分别为：LR=0.730、GBT=0.739、RF=0.733。梯度提升树（GBT）以最高 AUC 胜出，被选为最终模型。三者差距较小（约 0.009），说明在本数据集上特征工程的质量对最终性能影响更大，而非模型选择本身。




图 4-7 三种分类器验证集 AUC 对比（红色为最优模型 GBT）

4.3.3 融合权重 α 扫描（验证集）

在验证集候选对上扫描 $\alpha \in \{0.0, 0.1, \dots, 1.0\}$ ，以 AUC 为准则选择最优融合权重。如图所示，验证集 AUC 整体维持在约 0.000 的平台（候选集上正负标签比例极低导致 AUC 退化），但系统仍依规则确定最优 $\alpha = 0.55$ ，表明在候选集内模型概率权重略高于 CF 分数时效果最优。该结果也说明在稀疏候选场景下，AUC 本身不适合作为单一评判标准，应结合 Global hit@K 等排序指标综合考量。




图 4-8 融合权重 α 扫描（验证集 AUC）

4.3.4 CF 与融合对比（测试集 Global hit@10）

测试集 Global hit@10（候选中至少命中 1 个历史正样本的用户比例）：仅 CF 模式 = 58.02%，融合模式（ $\alpha=0.55$ ）= 58.02%，两者相同。这一结果说明在当前候选集规模和特征设计下，ML 模型的引入未能在排序层面提升 CF 候选的命中率。主要原因在于：候选集中 CF 已筛出了大部分相关物品，而模型特征（无 row-level 行为特征）在候选重排阶段的区分度有限， α 扫描的平台效应也印证了这一点。




图 4-9 仅 CF 与融合模型 Global hit@10 对比

4.3.5 Top-10 推荐品类分布（多样性截断后）

经多样性截断（同类别 ≤ 4 个）后的 Top-10 推荐列表中，Drama（约 1,390 次）和 Action（约 1,350 次）是被推荐次数最多的类别，与 EDA 中 Drama 样本量最大的结论吻合。Documentary 排第三（约 940 次），超过 Romance 和 Comedy，可能与品类代理 Top1 物品（cat_top1）的选择有关。Western 被推荐次数最少（约 325 次），与其数据集内样本稀少相符。多样性截断策略有效避免了推荐列表被单一热门类别主导。




图 4-10 Top-10 推荐品类分布（多样性截断后）

4.3.6 测试集指标汇总

测试集综合指标汇总如下：

指标	数值	说明
Strict Precision@10	0.000	候选 Top-10 中正好命中测试正样本的严格准确率
Strict Recall@10	0.000	测试正样本被严格命中的召回率
Global hit@10 (fused)	0.580	至少命中 1 个相关物品的用户比例（主要指标）
Global hit@10 (CF only)	0.580	纯 CF 排序命中率，与融合持平
Recall@10 (rel)	0.000	与 Strict Recall@10 相同
NDCG@10	0.000	归一化折损累积增益（候选集覆盖率限制）
Val AUC (GBT)	0.739	验证集上的 AUC，候选集标签稀疏下的替代指标
最优 α	0.55	ML 模型概率权重略高于 CF 分数




图 4-11 测试集排序/命中指标汇总（多样性 Top10）

注：Strict P/R@10 与 NDCG@10 均为 0.000，是由于测试集仅有 1 条正样本（每用户最后一次评分），而候选集来自 CF Top-10，测试正样本恰好全部落在候选集外（即 CF 未召回该物品）。这是 time_last 协议在小规模数据集上的典型现象：严格指标依赖候选集对测试正样本的精准覆盖，而 Global hit@10 则放宽为‘至少命中一个历史正样本’，因此更具参考价值（58.02%）。

4.4 运行时间统计

系统完整运行时间如下：MapReduce 流水线共 123 秒（本地模式，9 个阶段），Spark 流水线共 189 秒，总计约 312 秒（约 5.2 分钟）。实验在 Docker 容器内运行，Spark driver 分配约 3GB 内存，数据规模 100K 条记录，各阶段耗时合理。

自动化流水线调度：值得一提的是，系统的所有 9 个 MapReduce 阶段与 Spark 训练评估阶段并非手动分步执行，而是由一系列 Shell 脚本（如 run_mapreduce.sh 和 run_spark.sh）进行自动化串联。我们编写了顶层的调度脚本，实现了从数据预处理、HDFS 上传、MR 级联计算、Spark 融合排序到评估指标输出的“一键式、端到端”全自动化运行。这种 Pipeline 设计不仅避免了集群环境下的手动误操作，也极大地提升了大数据离线批处理的开发调试效率

五、团队沟通记录

群聊的聊天记录

2026-4-20 ~ 2026-4-29

胡林森 4/20 16:11:53

群聊的聊天记录

胡林森 2025/11/4 12:03:27
https://tianchi.aliyun.com/dataset/45/notebook

胡林森 2025/11/4 12:03:32
https://tianchi.aliyun.com/dataset/46/notebook

胡林森 2025/11/4 12:04:12
https://tianchi.aliyun.com/dataset/

胡林森 4/20 16:13:05

电商用户行为分析系统

核心内容：分析用户浏览、加购、下单等行为路径，挖掘用户偏好，构建用户画像。

数据来源：阿里云天池、Criteo 公开数据集等。

技术亮点：利用 MapReduce 或 Spark 进行行为序列分析，结合 Hive 做多维数据统计。

胡林森 4/20 16:13:19

电影评分与推荐系统

核心内容：基于用户评分数据，实现协同过滤推荐，分析热门电影趋势。

群聊的聊天记录

social_ecomm... data.csv
12.42M

胡林森 4/20 18:39:54

胡林森 4/20 18:42:46

郑智 4/21 00:57:35

项目背景：-

1. 为了提升学生的数据分析能力和团队协作能力，特举办本次项目。旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

2. 项目内容：本项目旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

3. 项目目标：本项目旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

4. 项目意义：本项目旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

5. 项目成果：本项目旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

6. 项目总结：本项目旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

7. 项目反思：本项目旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

8. 项目展望：本项目旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

9. 项目致谢：本项目旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

10. 项目附录：本项目旨在通过实际项目，锻炼学生的数据分析能力、团队协作能力、沟通能力、解决问题的能力等。

群聊的聊天记录

胡林森 4/26 20:17:18

命中率好像低的吓人

胡林森 4/26 20:18:05

可以远控环境配置好的电脑吗

郑智 4/28 14:50:41

啥时候交来着

郑智 4/28 14:50:51

五一前是吧

胡林森 4/28 14:51:03

对的

星期四去交吧

胡林森 4/28 14:51:33

效果好像很好，用的规范的数据库

胡林森 4/28 14:51:36

🤔

郑智 4/28 14:56:50

- MovieLens pipeline: remove ecommerce raw data, keep output/ with origin & main songyining64 昨天 16:52
- Recsys: time/LOO eval, leakage-free features, CF truth injection, val AUC splits songyining64 昨天 16:01
- Add README: setup, run, outputs, pipeline overview songyining64 2026/4/26 16:41
- Update evaluation outputs: stratified tables and charts songyining64 2026/4/26 16:39
- Initial commit: Hadoop Docker stack, MapReduce Item-CF pipeline, Spark recsys songyining64 2026/4/26 16:37

六、总结个人贡献与存在问题

6.1 项目总结

本项目以 MovieLens 100K 为数据基础，完整实现了“数据预处理 → HDFS 存储 → MapReduce Item-CF → Spark ML 融合评估”的离线推荐系统流水线。主要成果如下：

- 成功将 100K 条评分数据处理为标准 CSV 并上传 HDFS，MR 流水线在本地模式下 123 秒完成 9 个阶段任务；
- Item-CF 候选生成策略（用户共现 + 余弦相似度）使 Global hit@10 达到 58.02%，说明协同过滤对电影推荐具有良好的适应性；
- Spark ML 在验证集上训练出 $AUC = 0.739$ （GBT）的分类器，融合权重 $\alpha = 0.55$ 为最优；
- 多样性截断策略保证了推荐列表的品类覆盖，Drama/Action 等大类不会完全主导结果；

- 整个系统运行在 Docker 容器化环境中，具备一键复现能力（bash pipeline/run_all_docker.sh）。

6.2 存在问题与改进方向

- Strict P@10 / NDCG@10 = 0.000: time_last 协议下测试正样本（每用户最后一条记录）大多未被 CF 候选集召回，说明候选集覆盖率（Top-10）仍不足。改进方向：扩大 CF Top-N 至 50/100，或增加基于 ALS 的 MF 候选作为补充；
- ML 模型未提升命中率：当前特征以用户/物品 profile 统计特征为主，缺乏交叉特征（如用户-类别偏好）。可引入 FM/DeepFM 或加入 user_cf_history 交叉特征；
- 验证集 AUC 扫描平台效应：候选集正负比例极低，AUC 失去区分度。可改用 NDCG@K 或 MAP 作为融合选取标准；
- 冷启动处理较简单：当前新用户/物品回退到品类热门均值。可扩展为基于内容的 CBF 或人口统计相似用户的 user-CF 作为热启动方案；
- 数据规模较小：100K 数据在单机 Docker 下已足够，但在实际工业场景中需要 YARN 集群与更多数据分区，MapReduce 的并行优势才能充分体现。

6.3 个人贡献总结

成员	主要贡献	贡献占比
陈永睿	环境搭建、代码编写	39%
郑 智	代码微调、文档撰写	33%
胡林森	选题与思路分析、EDA.ipynb、报告排版	28%

教师评语：

报告成绩：

成员	个人分数
陈永睿	
郑 智	
胡林森	