



中国石油大学(北京)
CHINA UNIVERSITY OF PETROLEUM, BEIJING

《大数据分析算法》

实验报告

院（系）：石油学院

专业年级：数据科学与大数据技术 23 级

学 号：2023015509

姓 名：胡林森

序 号：34

完成日期：2026 年 4 月 20 日

目 录

一、 固定任务.....	1
1.1 问题描述.....	1
1.2 方法分析.....	1
1.2.1 Node2Vec 嵌入维度 (d) 的分析.....	1
1.2.2 PageRank 阻尼因子 (α) 的分析	1
1.3 实验结果.....	2
1.4 实验结论.....	4
1.4.1 结果分析.....	4
1.4.2 对比分析.....	5
1.5 小结.....	5
1.5.1 核心实验结论.....	5
1.5.2 关键发现与归因分析.....	5
1.5.3 改进方向.....	5
二、 开放任务.....	6
2.1 优化思路.....	6
2.1.1 融合节点原始特征 x	6
2.1.2 采用 Cora 论文标准划分	6
2.2 关键代码.....	7
2.3 实验结果.....	9
2.4 实验小结.....	10
三、 总结.....	10

一、固定任务

1.1 问题描述

本实验旨在通过受控变量法，探究图嵌入（Graph Embedding）表示能力与结构中心性（Structural Centrality）指标对节点分类任务的影响。

具体研究方向分为两个维度：

特征表达能力的深度与广度：通过调整 Node2Vec 嵌入维度 ($d \in \{64, 128, 256\}$)，研究特征空间容量对图拓扑信息捕捉的影响。

结构重要性的传播权重：通过调整 PageRank 阻尼因子 ($\alpha \in \{0.7, 0.85, 0.9\}$)，研究节点全局重要性对分类的辅助作用。 α 决定了随机游走在图中跟随边跳转与随机跳转的概率比，直接影响了 PageRank 分数在稠密与稀疏结构中的区分度。实验的目标是寻找最优的参数组合，使得在 Cora 引文网络上，融合后的特征向量能在分类器中获得更高的 Accuracy 和 Macro-F1 分数。

1.2 方法分析

1.2.1 Node2Vec 嵌入维度 (d) 的分析

Node2Vec 通过模拟二阶随机游走，将图中的节点映射到 d 维空间。

低维度 ($d = 64$)：特征空间较为拥挤，倾向于捕捉图中最为显著的宏观特征，但可能会丢失局部邻域的微观差异，导致分类边界模糊。

中维度 ($d = 128$)：常用基准，能够在保持模型泛化能力的同时，较好地平衡计算开销与信息完整性。

高维度 ($d = 256$)：提供了极大的表达空间，可以记录更复杂的路径模式。但在 Cora 这种节点数较少的数据集上，容易发生过拟合，导致在训练集上表现优秀但在测试集上性能下降。

1.2.2 PageRank 阻尼因子 (α) 的分析

PageRank 的计算公式可以表示为：
$$PR(u) = \frac{1-\alpha}{N} + \alpha \sum_{v \in B_u} \frac{PR(v)}{L(v)}$$

较低因子 ($\alpha = 0.7$)：随机跳转的概率较大。这意味着 PageRank 分数受局部结构影响减小，分布更加“平滑”，节点间的差异性降低。

经典因子 ($\alpha = 0.85$)：Google 经典的经验值，在维持图结构传播和防止陷入汇聚节点（Sink Nodes）之间取得了最佳平衡。

较高因子 ($\alpha = 0.9$)：强化了图中“边”的权威性。分数会高度向核心节点、权威论文聚集。

1.3 实验结果

```
D:\py\venv\2023015509\Scripts\python.exe E:\CUPK-lib\大数据分析算法\2023015509\2025pagerank.py
2026-04-20 21:58:54,642 - INFO - 开始加载Cora引文网络数据集...
2026-04-20 21:58:54,682 - INFO - 数据集统计: 节点数=2708, 边数=5278
2026-04-20 21:58:54,687 - INFO - 类别数=7, 特征维度=1433
2026-04-20 21:58:54,690 - INFO - 训练集数=140, 测试集数=1000
2026-04-20 21:58:54,691 - INFO - 开始计算PageRank, 阻尼因子alpha=0.85
2026-04-20 21:58:54,701 - INFO - PageRank计算完成, 分数范围=[0.000000, 1.000000]
2026-04-20 21:58:54,701 - INFO - 开始训练Node2Vec, 参数={'node2vec_dim': 128, 'node2vec_walk_len':
2026-04-20 21:59:00,183 - INFO - Node2Vec训练完成, 嵌入维度=128
2026-04-20 21:59:00,192 - INFO - 开始构造实验特征...|
2026-04-20 21:59:00,194 - INFO - 特征构造完成: 纯Node2Vec维度=(2708, 128), 融合特征维度=(2708, 129)
2026-04-20 21:59:00,194 - INFO - 开始训练与评估: 纯Node2Vec
```

```
2026-04-20 21:59:00,975 - INFO - 纯Node2Vec - 5折交叉验证: Acc=0.2290, Macro-F1=0.1269
2026-04-20 21:59:01,067 - INFO - 纯Node2Vec - 测试集分类报告:
      precision    recall  f1-score   support

         0         0.09      0.04      0.06         70
         1         0.18      0.05      0.07         43
         2         0.19      0.14      0.16         84
         3         0.32      0.67      0.43        164
         4         0.22      0.15      0.18         85
         5         0.00      0.00      0.00         60
         6         0.00      0.00      0.00         36

    accuracy
macro avg      0.14      0.15      0.13        542
weighted avg   0.18      0.26      0.20        542

2026-04-20 21:59:01,068 - INFO - 开始训练与评估: Node2Vec+PageRank
```

```
2026-04-20 21:59:02,031 - INFO - Node2Vec+PageRank - 测试集分类报告:
      precision    recall  f1-score   support

         0         0.09      0.04      0.06         70
         1         0.18      0.05      0.07         43
         2         0.20      0.14      0.17         84
         3         0.31      0.67      0.43        164
         4         0.22      0.15      0.18         85
         5         0.00      0.00      0.00         60
         6         0.00      0.00      0.00         36

    accuracy
macro avg      0.14      0.15      0.13        542
weighted avg   0.19      0.26      0.20        542

2026-04-20 21:59:02,652 - INFO - 实验结果图已保存至: ./graph_experiment/figures/result_comparison.png
2026-04-20 21:59:19,413 - INFO - 网络结构图已保存至: ./graph_experiment/figures/cora_graph.png
2026-04-20 21:59:19,413 - INFO - =====实验结论=====
2026-04-20 21:59:19,413 - INFO - PageRank特征对Accuracy的测试集变化: +0.00 个百分点
2026-04-20 21:59:19,413 - INFO - PageRank特征对Macro-F1的测试集变化: +0.01 个百分点
```

本次实验（0.85-128）结果

指标（测试集）	纯 Node2Vec	Node2Vec + PageRank	提升幅度
---------	------------	---------------------	------

Accuracy (准确率)	0.26	0.26	+0.00%
Macro-F1	0.13	0.13	+0.01%

对比实验结果：

表 1 各参数组合结果

Accuracy	$\alpha=0.7$	$\alpha=0.85$	$\alpha=0.9$
Dim=64	0.27	0.28	0.27
Dim=128	0.25	0.26	0.25
Dim=256	0.24	0.25	0.23

热力图

各组结论

0.7—64

2026-04-20 23:24:42,970 - INFO - PageRank 特征对 Accuracy 的测试集变化：+0.18%

2026-04-20 23:24:42,970 - INFO - PageRank 特征对 Macro-F1 的测试集变化：+0.05%

2026-04-20 23:24:42,970 - INFO - 实验结论：本次超参数与随机划分下，PageRank 带来的提升很小；这不代表方法无效，可尝试增大 Node2Vec 游走长度/次数、换随机种子多次平均，或改用 Cora 论文标准 train/val/test 划分对比。

0.7—128

2026-04-20 23:26:11,523 - INFO - PageRank 特征对 Accuracy 的测试集变化：-0.18%

2026-04-20 23:26:11,523 - INFO - PageRank 特征对 Macro-F1 的测试集变化：-0.26%

2026-04-20 23:26:11,523 - INFO - 实验结论：本次超参数与随机划分下，PageRank 带来的提升很小；这不代表方法无效，可尝试增大 Node2Vec 游走长度/次数、换随机种子多次平均，或改用 Cora 论文标准 train/val/test 划分对比。

0.7—256

2026-04-20 22:30:43,135 - INFO - PageRank 特征对 Accuracy 的测试集变化：+0.74%

2026-04-20 22:30:43,135 - INFO - PageRank 特征对 Macro-F1 的测试集变化：+0.48%

2026-04-20 22:30:43,135 - INFO - 实验结论：在本设置下，融合 PageRank 对节点分类指标带来可见正向变化（可进一步调参或换划分验证）。

0.85—64

2026-04-20 23:35:02,981 - INFO - PageRank 特征对 Accuracy 的测试集变化：+0.00%

2026-04-20 23:35:02,981 - INFO - PageRank 特征对 Macro-F1 的测试集变化：-0.01%

2026-04-20 23:35:02,981 - INFO - 实验结论：本次超参数与随机划分下，PageRank 带来的提升很小；这不代表方法无效，可尝试增大 Node2Vec 游走长度/次数、换随机种子多次平均，或改用 Cora 论文标准 train/val/test 划分对比。

0.85—128

2026-04-20 23:33:05,386 - INFO - PageRank 特征对 Accuracy 的测试集变化：+0.18%

2026-04-20 23:33:05,386 - INFO - PageRank 特征对 Macro-F1 的测试集变化：+0.20%

2026-04-20 23:33:05,386 - INFO - 实验结论：本次超参数与随机划分下，PageRank 带来的提

升很小；这不代表方法无效，可尝试增大 Node2Vec 游走长度/次数、换随机种子多次平均，或改用 Cora 论文标准 train/val/test 划分对比。

0.85—256

2026-04-20 23:31:54,265 - INFO - PageRank 特征对 Accuracy 的测试集变化: -0.18%

2026-04-20 23:31:54,265 - INFO - PageRank 特征对 Macro-F1 的测试集变化: -0.17%

2026-04-20 23:31:54,265 - INFO - 实验结论: 本次超参数与随机划分下, PageRank 带来的提升很小; 这不代表方法无效, 可尝试增大 Node2Vec 游走长度/次数、换随机种子多次平均, 或改用 Cora 论文标准 train/val/test 划分对比。

0.9—64

2026-04-20 23:29:49,337 - INFO - PageRank 特征对 Accuracy 的测试集变化: +0.00%

2026-04-20 23:29:49,337 - INFO - PageRank 特征对 Macro-F1 的测试集变化: -0.00%

2026-04-20 23:29:49,337 - INFO - 实验结论: 本次超参数与随机划分下, PageRank 带来的提升很小; 这不代表方法无效, 可尝试增大 Node2Vec 游走长度/次数、换随机种子多次平均, 或改用 Cora 论文标准 train/val/test 划分对比。

0.9—128

2026-04-20 23:28:17,777 - INFO - PageRank 特征对 Accuracy 的测试集变化: +0.18%

2026-04-20 23:28:17,777 - INFO - PageRank 特征对 Macro-F1 的测试集变化: +0.06%

2026-04-20 23:28:17,777 - INFO - 实验结论: 本次超参数与随机划分下, PageRank 带来的提升很小; 这不代表方法无效, 可尝试增大 Node2Vec 游走长度/次数、换随机种子多次平均, 或改用 Cora 论文标准 train/val/test 划分对比。

0.9—256

2026-04-20 23:30:59,534 - INFO - PageRank 特征对 Accuracy 的测试集变化: +0.18%

2026-04-20 23:30:59,534 - INFO - PageRank 特征对 Macro-F1 的测试集变化: +0.26%

2026-04-20 23:30:59,534 - INFO - 实验结论: 本次超参数与随机划分下, PageRank 带来的提升很小; 这不代表方法无效, 可尝试增大 Node2Vec 游走长度/次数、换随机种子多次平均, 或改用 Cora 论文标准 train/val/test 划分对比。

1.4 实验结论

1.4.1 结果分析

结论: 本次超参数与随机划分下, PageRank 带来的提升很小; 这不代表方法无效, 可尝试增大 Node2Vec 游走长度/次数、换随机种子多次平均, 或改用 Cora 论文标准 train/val/test 划分对比。

数据归一化问题: 日志显示 PageRank 分数范围=[0.000000, 1.000000]。在正常的 PageRank 算法中, 除非图极度特殊, 否则单个节点很难达到 1.0。

训练集规模: Cora 默认的训练集只有 140 个节点 (每个类 20 个)。在如此少的数据下, 仅靠 128 维的结构特征 是很难泛化的。

实验结果表明, 在标签信息极度稀疏的情况下, 单纯的拓扑结构嵌入不足以支撑高精度的节点分类。

1.4.2 对比分析

嵌入维度的影响

三个维度下的 Accuracy 呈现单调递减趋势：Dim=64（均值 ≈ 0.273 ）>Dim=128（ ≈ 0.253 ）>Dim=256（ ≈ 0.240 ）。这个结果初看反直觉，但在 Cora 数据集上有合理解释：Node2Vec 训练数据量有限（游走次数仅 20 次），高维嵌入容易出现欠拟合——参数空间太大但有效训练信号不足，导致嵌入质量反而下降。

阻尼因子的影响

三个阻尼因子值的区别不大，整体在同一维度下差异在 0.01 以内。 $\alpha=0.85$ 表现最稳定，这与 PageRank 理论吻合——0.85 是学界公认的最优默认值，过低（0.7）会让随机游走权重过高，过高（0.9）则使 PR 分数分布过于集中。

1.5 小结

1.5.1 核心实验结论

本实验通过在 Cora 数据集上对 Node2Vec 嵌入维度与 PageRank 阻尼因子 α 进行交叉验证，得出以下核心结论：模型表现受限：由于仅使用了拓扑结构特征而忽略了节点内容特征，各参数组合下的准确率（Accuracy）均处于 23% - 28% 的较低区间。参数敏感度：嵌入维度 d 是影响分类性能的主导因素，而 阻尼因子 α 对最终结果的波动影响较小（控制在 $\pm 1\%$ 以内）。PageRank 的边际增益：在绝大多数配置下，融合 PageRank 带来的性能提升极微（平均 +0.1% 左右），但在高维噪声环境下（如 $d = 256$ ）表现出了一定的稳健性。

1.5.2 关键发现与归因分析

1. 嵌入维度的“倒挂”现象 (Dimension Overfitting) 实验数据显示准确率呈现 $Dim = 64 > Dim = 128 > Dim = 256$ 的单调递减趋势。归因分析：Cora 数据集规模较小（2708 节点），且本实验中 Node2Vec 的采样强度较低（游走次数 20）。

在这种情况下，低维空间（64）能更有效地压缩并聚类结构特征；而高维空间（256）由于参数过多，在样本稀疏的情况下极易产生过拟合或因训练不充分导致的“表达弥散”，从而降低了分类器的判别能力。

2. 阻尼因子 α 的稳健性与局限性现象： $\alpha = 0.85$ 在三个维度下均保持了相对最优。归因分析：这验证了经典的随机游走平衡理论。虽然调整 α 能改变全局重要性的权重分配，但在标签信息极度稀疏的背景下，全局中心性的微调很难直接转化为分类面的结构性改善。

3. PageRank 分数分布的潜在异常现象检测：日志显示的 PR 分数范围达到 $[0,1]$ ，显著高于理论平均值。改进建议：这表明原始 PR 分数存在极端的长尾分布，导致分类器权重可能忽略了这一维度。

1.5.3 改进方向

补齐特征缺失。

改进训练集划分，用 Cora 论文的标准划分（Fixed Split），以增强实验间的可比性。

二、开放任务

2.1 优化思路

2.1.1 融合节点原始特征 x

背景：原始代码仅使用图拓扑结构（Node2Vec 嵌入），忽略了 Cora 每个节点自带的 1433 维词袋特征，信息利用不充分。

优化内容：将节点原始特征 x 经 StandardScaler 标准化后，与 Node2Vec 嵌入拼接，构成融合特征向量。

标准化的目的是消除量纲差异，防止 1433 维的高维特征在数值上淹没 128 维的嵌入向量。

对比方案：

实验设计为四组特征横向对比——纯 Node2Vec / Node2Vec+PageRank / Node2Vec+ x / Node2Vec+PageRank+ x ，可量化评估每类特征的独立贡献与联合效果。

2.1.2 采用 Cora 论文标准划分

问题背景：原始代码使用随机 80/20 划分，每次实验结果受随机种子影响，且无法与权威文献的数值直接对比。

优化内容：改用 Cora 数据集内置的标准 train/val/test mask，训练集固定 140 条（每类 20 条）、测试集固定 1000 条

优势：结果具备可复现性与横向可比性，便于在论文中与 GCN、GAT 等方法的公开数值进行对比分析。

2.2 关键代码

```
def load_cora_data():
    """
    加载 Cora, 返回:
    G          - NetworkX 图 (拓扑)
    labels     - 所有节点标签 (N,)
    node_x     - 节点原始词袋特征 (N, 1433), 已按 sorted(G.nodes()) 排好序
    masks      - dict: train_mask / val_mask / test_mask (Cora 标准划分, 布尔数组)
    """
    logger.info("开始加载 Cora 引文网络数据集...")
    dataset = Planetoid(root="./graph_experiment/Cora", name="Cora")
    data = dataset[0]

    G = to_networkx(data, to_undirected=True)
    node_list = sorted(G.nodes()) # 保证特征行序与节点一一对应

    labels = data.y.numpy()

    # 提取节点原始特征x, 按node_list顺序排列
    raw_x = data.x.numpy() # shape (N, 1433), 节点 id 即行号
    node_x = raw_x[node_list] # 按 sorted 节点顺序重新索引 (Cora 节点 id 连续, 一般等价)

    # Cora标准划分mask
    masks = {
        "train": data.train_mask.numpy()[node_list],
        "val": data.val_mask.numpy()[node_list],
        "test": data.test_mask.numpy()[node_list],
    }

    logger.info(f"节点数={G.number_of_nodes()}, 边数={G.number_of_edges()}")
    logger.info(f"类别数={dataset.num_classes}, 原始特征维度={dataset.num_node_features}")
    logger.info(
        f"标准划分 - 训练: {masks['train'].sum()} / 验证: {masks['val'].sum()} / 测试: {masks['test'].sum()}"
    )

    return G, labels[node_list], node_x, masks, node_list
```

```
# ----- 4. 特征构造 (4种对比方案) -----
def construct_all_features(w2v, pr_feat, node_x, node_list, params):
    """
    返回 4 组特征 (均已对原始特征 x 做 StandardScaler 归一化):
    X_n2v      : 纯 Node2Vec (N, 128)
    X_n2v_pr    : Node2Vec + PageRank (N, 129)
    X_n2v_x     : Node2Vec + 原始特征 x (N, 128+1433)
    X_n2v_pr_x  : Node2Vec + PageRank + 原始特征 x (N, 130+1433)
    """
    logger.info("构造 4 组对比特征...")

    # Node2Vec 嵌入 (按 node_list 顺序)
    emb = np.array([w2v.wv[n] for n in node_list]) # (N, dim)

    # 方向1: 对原始 x 做标准化 (量纲对齐, 防止高维特征淹没嵌入)
    scaler = StandardScaler()
    x_scaled = scaler.fit_transform(node_x) # (N, 1433)

    X_n2v = emb
    X_n2v_pr = np.hstack([emb, pr_feat])
    X_n2v_x = np.hstack([emb, x_scaled]) # ← 核心新增
    X_n2v_pr_x = np.hstack([emb, pr_feat, x_scaled]) # ← 全融合

    for name, X in [("Node2Vec", X_n2v), ("+PageRank", X_n2v_pr),
                    ("+x特征", X_n2v_x), ("+PageRank+x", X_n2v_pr_x)]:
        logger.info(f" {name} 维度={X.shape}")

    return X_n2v, X_n2v_pr, X_n2v_x, X_n2v_pr_x
```

```
def train_and_evaluate_standard(X, y, masks, params, name):
    """
    使用 Cora 论文标准 train/val/test 划分
    训练集: 140条 (20类×7) | 测试集: 1000条 (论文固定)
    5折 CV 在标准训练集上做
    """
    X_tr, y_tr = X[masks["train"]], y[masks["train"]]
    X_te, y_te = X[masks["test"]], y[masks["test"]]

    clf = LogisticRegression(max_iter=params["lr_max_iter"], random_state=SEED, n_jobs=-1)

    # 训练集仅 140 条, cv_folds 设为 5 时每折 ~28 条, 仍可运行
    cv_folds = min(params["cv_folds"], len(y_tr) // 7)
    cv_acc = cross_val_score(clf, X_tr, y_tr, cv=cv_folds, scoring="accuracy").mean()
    cv_f1 = cross_val_score(clf, X_tr, y_tr, cv=cv_folds, scoring="f1_macro").mean()

    clf.fit(X_tr, y_tr)
    y_pred = clf.predict(X_te)
    test_acc = accuracy_score(y_te, y_pred)
    test_f1 = f1_score(y_te, y_pred, average="macro")

    logger.info(f"[标准划分] {name} - CV Acc={cv_acc:.4f}, CV F1={cv_f1:.4f}")
    logger.info(f"[标准划分] {name} - Test Acc={test_acc:.4f}, Test F1={test_f1:.4f}")
    logger.info(f"分类报告: \n{classification_report(y_te, y_pred)}")

    return {
        "name": name,
        "cv_acc": cv_acc, "cv_f1": cv_f1,
        "test_acc": test_acc, "test_f1": test_f1,
    }
```

2.3 实验结果

```

D:\py\.venv\2023015509\Scripts\python.exe E:\CUPK-lib\大数据分析算法\2023015509\2025pagerank_optimized.p
2026-04-20 23:58:06,011 - INFO - 开始加载 Cora 引文网络数据集...
2026-04-20 23:58:06,036 - INFO - 节点数=2708, 边数=5278
2026-04-20 23:58:06,037 - INFO - 类别数=7, 原始特征维度=1433
2026-04-20 23:58:06,037 - INFO - 标准划分 - 训练:140 / 验证:500 / 测试:1000
2026-04-20 23:58:06,037 - INFO - 计算 PageRank, alpha=0.85
2026-04-20 23:58:06,044 - INFO - PageRank 范围=[0.000000, 1.000000]
2026-04-20 23:58:06,044 - INFO - 训练 Node2Vec, dim=128
2026-04-20 23:58:15,701 - INFO - Node2Vec 训练完成
2026-04-20 23:58:15,713 - INFO - 构造 4 组对比特征...
2026-04-20 23:58:15,785 - INFO - Node2Vec 维度=(2708, 128)
2026-04-20 23:58:15,785 - INFO - +PageRank 维度=(2708, 129)
2026-04-20 23:58:15,785 - INFO - +x特征 维度=(2708, 1561)
2026-04-20 23:58:15,786 - INFO - +PageRank+x 维度=(2708, 1562)



```


[随机划分] +PR+x - CV Acc=0.7174 F1=0.6939 | Test Acc=0.7472 F1=0.7163

[标准划分] 纯 N2V - Test Acc=0.1290, Test F1=0.1233

[标准划分] +PR - Test Acc=0.1290, Test F1=0.1233

[标准划分] +x - Test Acc=0.4800, Test F1=0.4849





2.4 实验小结

```

2026-04-20 23:58:27,703 - INFO - |
===== 实验结论汇总 =====
2026-04-20 23:58:27,703 - INFO - 方案          随机_Acc    随机_F1    标准_Acc    标准_F1
2026-04-20 23:58:27,703 - INFO - 纯N2V          0.2417    0.1195    0.1290    0.1233
2026-04-20 23:58:27,703 - INFO - +PR           0.2417    0.1195    0.1290    0.1233
2026-04-20 23:58:27,703 - INFO - +x            0.7472    0.7163    0.4800    0.4849
2026-04-20 23:58:27,703 - INFO - +PR+x         0.7472    0.7163    0.4800    0.4849
2026-04-20 23:58:27,703 - INFO -
标准划分下最优方案: +x, Test Acc=0.4800
2026-04-20 23:58:27,703 - INFO - +PR 相对纯N2V提升: +0.00 个百分点
2026-04-20 23:58:27,703 - INFO - +x  相对纯N2V提升: +35.10 个百分点
2026-04-20 23:58:27,703 - INFO - +PR+x 相对纯N2V提升: +35.10 个百分点

```

x 特征是决定性因素，加入后随机划分 Accuracy 从 0.24 升至 0.75，提升幅度达+35%，本次实验最显著的优化效果。

PageRank 贡献为零，无论是否加入 x 特征，+PR 的结果与不加几乎相同，说明在逻辑回归分类器下，单维度 PageRank 分数被 128 维嵌入或 1433 维 x 特征完全覆盖，没有提供额外的判别信息。

随机划分下+x 达到 0.747，但标准划分下只有 0.480，差距很大。原因是标准划分训练集仅 140 条（每类 20 条），逻辑回归在 1433 维特征上严重欠拟合，而随机划分有 80% 的数据可用于训练，条件宽松得多。这也说明标准划分的结果更能反映方法的真实泛化能力。

但整体仍然**偏弱**，标准划分 0.48 距离 Cora 上的主流方法差距明显——GCN 论文基准约 0.81。

三、总结

3.1 核心实验结论

本实验通过受控变量法，在 Cora 数据集上对 Node2Vec 嵌入维度(d)与 PageRank 阻尼因子(α)进行了交叉验证，并进一步引入节点原始特征进行优化，得出以下结论：

1. 特征贡献度差异显著：节点原始特征(x)是决定分类性能的关键因素，而单纯的拓扑特征（Node2Vec 和 PageRank）在信息表达上存在局限性。
2. 参数敏感度分布：在拓扑特征中，嵌入维度 d 对性能的影响占据主导地位，而阻尼因子 α 的波动对最终结果的影响微乎其微（波动基本控制在 $\pm 1\%$ 以内）。

3. PageRank 的边际效应：在逻辑回归分类器下，PageRank 分数提供的全局重要性信息极易被高维嵌入或原始特征覆盖，导致其带来的性能提升几乎为零。

3.2 关键发现与归因分析

A. 嵌入维度的“倒挂”现象(Dimension Overfitting)实验数据显示准确率呈现 $Dim = 64 > Dim = 128 > Dim = 256$ 的单调递减趋势。

Cora 数据集规模较小(2708 节点)，且实验中 Node2Vec 采样强度较低(游走次数 20)。在这种情况下，高维空间(256)由于参数过多且训练信号不足，极易产生过拟合，导致嵌入向量的判别能力反而下降。

B. 原始特征(x)的决定性作用引入 1433 维词袋特征后，分类性能实现了质的飞跃。

数据支撑：在随机划分下，加入 x 特征使 Accuracy 从 0.24 飙升至 0.75，提升幅度达 +35%。这证明了在引文网络中，论文的内容信息比单纯的引用结构包含更多分类判别依据。

C. 划分方式对泛化评估的影响实验对比了“随机划分”与“标准划分”的效果：现象：标准划分下(训练集仅 140 条)的 Accuracy (0.48) 远低于随机划分 (0.75)。

结论：标准划分能更真实地反映模型的泛化能力。在极稀疏的标签环境下，逻辑回归在超高维特征上容易出现欠拟合。

3.3 改进方向

尽管引入原始特征大幅提升了性能，但距离主流方法(如 GCN 基准约 0.81)仍有差距。后续可考虑：

模型升级：使用能同时学习结构与内容的图卷积网络(GCN)或图注意力网络(GAT)。

数据增强：增大 Node2Vec 的随机游走长度与次数，以获得更稳健的结构嵌入。

特征工程：对 PageRank 等中心性指标进行非线性变换，以缓解长尾分布带来的权重稀释问题。