

Lecture 1: Random Experiment, Sample Space and Event

1. 自然界所观察到的现象：确定性现象和随机现象

- 在一定条件下必然出现的现象，称为**确定性现象**；
- 在一定条件下可能出现也可能不出现的现象，称为**随机现象**。

概率论是研究随机现象规律性的一门数学学科。

2. 定义：在概率论中，把具有以下三个特征的试验称为随机试验（Random Experiment）。

- (1) 可以在相同的条件下重复地进行；
- (2) 每次试验的可能结果不止一个，并且能事先明确试验的所有可能结果；
- (3) 进行一次试验之前不能确定哪一个结果会出现。

3. 定义：随机试验 E 的所有可能结果组成的集合称为 E 的**样本空间**（Sample Space），记为 S 。样本空间的元素，即试验 E 的每一个结果，称为**样本点**（Sample Point）。

4. 定义：随机试验 E 的样本空间 S 的子集称为 E 的**随机事件**（Random Event），简称**事件**（Event）。

5. 随机事件的分类：

- 只含一个样本点的事件称为**基本事件**（Elementary Event）
- 含有多于一个样本点的事件称为**复合事件**（Compound Event）
- Ω ： **必然事件**（Certain Event）
- \emptyset ： **不可能事件**（Impossible Event）

必然事件的对立面是不可能事件，不可能事件的对立面是必然事件，它们互称为**对立事件** (Complementary Event)。

6. 事件的关系：设试验 E 的样本空间为 S ，而 $A, B, A_k (k = 1, 2, \dots)$ 是 S 的子集。

- (1) **包含关系**：若事件 A 出现，必然导致 B 出现，则称事件 B 包含事件 A ，记作 $A \subset B$ (或 $B \supset A$)；
- (2) **A 等于 B**：若事件 A 包含事件 B ，而且事件 B 包含事件 A ，则称事件 A 与事件 B 相等，记作 $A=B$ 。

- (3) **事件 A 与 B 的并 (和事件)**：“事件 A, B 至少有一个发生”称为事件 A 与 B 的**和或并** (union)，记作 $A \cup B$ (或 $A + B$)；

推广：如 n 个事件的并

$$\bigcup_{i=1}^n A_i = \text{“事件 } A_1, \dots, A_n \text{ 至少有一个发生”}$$

可数个事件的并

$$\bigcup_{i=1}^{\infty} A_i = \text{“事件 } A_1, A_2, \dots \text{ 至少有一个发生”}$$

- (4) **事件 A 与 B 的交 (积事件)**：“事件 A, B 同时发生”称为事件 A 与 B 的**积或交** (intersection)，记作 AB (或 $A \cap B$)；推广： n 个事件的交

$$\bigcap_{i=1}^n A_i = \text{“事件 } A_1, \dots, A_n \text{ 全都发生”}$$

可数个事件的交

$$\bigcap_{i=1}^{\infty} A_i = \text{“事件 } A_1, A_2, \dots \text{ 全都发生”}$$

- (5) **事件 A 与 B 互不相容 (互斥)**：若事件 A 的出现必然导致事件 B 不出现， B 出现也必然导致 A 不出现，则称事件 A 与 B 互不相容，即 $A \cap B = AB = \emptyset$ ；

- (6) **事件 A 与 B 的差**：由事件 A 出现而事件 B 不出现所组成的事件称为事件 A 与 B 的差，记作 $A - B$ ；

- (7) **事件 A 的对立事件**: 设 A 表示“事件 A 出现”, 则“事件 A 不出现”称为事件 A 的对立事件或逆事件, 记作 \bar{A} 。若 A 与 B 互逆, 则有 $A \cup B = S$ $AB = \emptyset$ 。

7. 事件的运算: 设 A, B, C 为事件, 则有

- (1) 交换律: $AB = BA$, $A \cup B = B \cup A$
- (2) 结合律: $(AB)C = A(BC)$, $(A \cup B) \cup C = A \cup (B \cup C)$
- (3) 分配律: $A(B \cup C) = AB \cup AC$, $A(B - C) = AB - AC$
- (4) 德·摩根律 (对偶律): $\overline{A \cap B} = \bar{A} \cup \bar{B}$, $\overline{A \cup B} = \bar{A} \cap \bar{B}$

Lecture 2: Frequency and Probability

1. 在相同条件下, 进行了 n 次试验, 在这 n 次试验中, 事件 A 发生的次数 n_A 被成为事件 A 发生的**频数**, 比值 $\frac{n_A}{n}$ 被称为事件 A 发生的**频率** (Frequency), 并计作 $f_n(A)$.

2. 在相同条件下重复进行的试验中, 若随着试验次数 n 的增加, 事件 A 发生的频率稳定在某一常数 p 附近, 则称 p 为事件 A 的**概率**, 记作 $P(A) = p$.

3. 定义: 设 E 是随机试验, S 是它的样本空间。对于 E 的每一事件 A 赋予一个实数, 记为 $P(A)$ 。若集合函数 $P(\cdot)$ 满足下列条件:

- (1) 非负性 (Nonnegativity): 对于每一个事件 A , 有 $P(A) \geq 0$;
- (2) 规范性 (Normalization): 对于必然事件 S , 有 $P(S) = 1$;
- (3) 可列可加性 (Countable Additivity): 设 A_1, A_2, \dots 是两两互不相容的事件, 则

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

则称 $P(A)$ 为事件 A 的概率 (Probability)。

4. 概率的主要性质:

- (1) $P(\emptyset) = 0$;
- (2) 若 A_1, A_2, \dots, A_n 是两两互不相容的事件, 则 $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$;
- (3) 设 A, B 为两个事件, 且 $A \subset B$, 则 $P(A) < P(B), P(B - A) = P(B) - P(A)$;
- (4) 对于任一事件 A , $P(A) < 1$;
- (5) 设 \bar{A} 是 A 的对立事件, 则 $P(\bar{A}) = 1 - P(A)$;
- (6) (加法公式) 对于任意两事件 A, B 有 $P(A \cup B) = P(A) + P(B) - P(AB)$ 。

Lecture 3: Counting Rule

1. **等可能概率模型（古典概型）**：如果一个随机试验 E 具有以下特点：（1）试验的样本空间只包含有限个样本点；（2）试验中每个基本事件/样本点发生的可能性相等。则称此随机试验是古典型的。此时对每个事件 $A \subset \Omega$,

$$P(A) = \frac{\text{事件 } A \text{ 包含样本点的个数}}{\text{样本点总数}} = \frac{n(A)}{n(\Omega)}$$

称为事件 A 的**古典概率**。

2. **几何概型**：当随机试验的样本空间是某个区域，并且任意一点落在度量（长度、面积、体积）相同的子区域是等可能的，则事件 A 的概率可定义为

$$P(A) = \frac{S_A}{S}$$

。

Lecture 4: Conditional Probability

1. 设 A, B 是两个事件, 且 $P(A) > 0$, 称

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为事件 A 发生的条件下事件 B 发生的**条件概率** (Conditional Probability)。

2. 条件概率的主要性质:

- (1) 非负性: $P(B|A) \geq 0$;
- (2) 规范性: $P(S|B) = 1, P(\emptyset|B) = 0$;
- (3) $P(B_1 \cup B_2|A) = P(B_1|A) + P(B_2|A) - P(B_1 B_2|A)$;
- (4) $P(B|A) = 1 - P(\bar{A}|B)$;
- (5) 可列可加性: 设 B_1, B_2, \dots 是两两互不相容的事件, 则有

$$P\left(\bigcup_{i=1}^{\infty} B_i|A\right) = \sum_{i=1}^{\infty} P(B_i|A)$$

。

3. 乘法原理 (Multiplication Rule): 由条件概率的定义, 得到

- 若 $P(A) > 0$, 则有 $P(AB) = P(A)P(B|A)$;
- 若 $P(AB) > 0$, 则有 $P(ABC) = P(C|AB)P(B|A)P(A)$;
- 若 $P(A_1 A_2 \cdots A_{n-1}) > 0$, 则有

$$P(A_1 A_2 \cdots A_n) = P(A_n|A_1 A_2 \cdots A_{n-1})P(A_{n-1}|A_1 A_2 \cdots A_{n-2}) \cdots P(A_2|A_1)P(A_1)$$

4. 定义: 设 S 为试验 E 的样本空间, A_1, A_2, \dots, A_n 为 E 的一组事件。若以下条件成立:

1. A_1, A_2, \dots, A_n 两两互斥: $A_i, A_j = \emptyset, i \neq j, i, j = 1, 2, \dots, n$;
2. $A_1 \cup A_2 \cup \cdots \cup A_n = S$,

则称 A_1, A_2, \dots, A_n 为样本空间 S 的一个**划分** (Partition)。

5. **全概率公式** (Law of Total Probability): 设试验 E 的样本空间为 S , B 为 E 的事件, A_1, A_2, \dots, A_n 为 S 的一个划分, 且 $P(A_i) > 0 (i = 1, 2, \dots, n)$, 则

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

6. **贝叶斯公式** (Bayes' Theorem): 设试验 E 的样本空间为 S , B 为 E 的事件, A_1, A_2, \dots, A_n 为 S 的一个划分, 且 $P(B) > 0, P(A_i) > 0 (i = 1, 2, \dots, n)$, 则

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{i=1}^n P(B|A_i)P(A_i)}$$

Lecture 5: Independence

1. 若两事件 A, B 满足 $P(AB) = P(A)P(B)$, 则称事件 A, B 相互独立 (Independence)。

2. 若三个事件 A, B, C 满足 $P(AB|C) = P(A|C)P(B|C), P(C) > 0$, 则称事件 A, B 条件独立 (Conditional Independence)。

3. 设 A, B, C 是三个事件, 如果满足等式

$$\begin{cases} P(AB) = P(A)P(B) \\ P(AC) = P(A)P(C) \\ P(BC) = P(B)P(C) \end{cases}$$

则称事件 A, B, C 两两相互独立 (Pairwise Independence)。

4. 设 A, B, C 是三个事件, 如果满足等式

$$\begin{cases} P(AB) = P(A)P(B) \\ P(AC) = P(A)P(C) \\ P(BC) = P(B)P(C) \\ P(ABC) = P(A)P(B)P(C) \end{cases}$$

则称事件 A, B, C 相互独立。

5. 设 A_1, A_2, \dots, A_n 是 n 个事件, 如果对于任意 $k (1 < k \leq n)$, 任意 $1 \leq i_1 < i_2 < \dots < i_k \leq n$, 具有等式

$$P(A_{i_1} A_{i_2} \dots A_{i_k}) = P(A_{i_1}) P(A_{i_2}) \dots P(A_{i_k}).$$

则称 A_1, A_2, \dots, A_n 为相互独立的事件。

6. 设 A, B 是两事件, 且 $P(A) > 0$ 。若 A, B 相互独立, 则 $P(B|A) = P(B)$, 反之亦然。

7. 设 $n (n \geq 2)$ 个事件 A_1, A_2, \dots, A_n 相互独立, 则

(1) 其中任意 $k (k \geq 2)$ 个事件也是相互独立的;

- (2) 将若干个 A_i 用 \bar{A}_i 替换后, 得到的新事件集也相互独立;
- (3) 特别地, 我们有

$$P(A_1 \cup \cdots \cup A_n) = 1 - P(\bar{A}_1) \cdots P(\bar{A}_n).$$

Lecture 6: Discrete Random Variable

1. 设 E 是随机试验，它的样本空间是 $S = e$ 。如果对于每一个 $e \in S$ ，又一个实数 $X(e)$ 与之对应，这样就得到一个定义在 S 上的单值实值函数 $X(e)$ ，称 $X(e)$ 为**随机变量** (Random Variable, RV)。

2. 设离散型随机变量 X 所有可能取的值为 $x_k (k = 1, 2, \dots)$ ， X 各个可能值的概率，即事件 $X = x_k$ 的概率，为 $P(X = x_k) = p_k, k = 1, 2, \dots$ 。称此为离散型随机变量 X 的分布律。称离散型随机变量特定值的取值为概率质量函数 (Probability Mass Function, PMF): $p_X(x) = P(X = x)$ 。

3. 分布律 $\{p_k\}$ 的主要性质:
$$\begin{cases} p_k \geq 0, & k = 1, 2, \dots \\ \sum_k p_k = 1 \end{cases}$$

4. 常见的离散型分布:

(1) 若随机变量 X 只可能取 0 和 1 两个值，它的分布律为

X	0	1
P	$1-p$	p

则称 X 服从参数为 p 的**两点分布** (或 **0-1 分布**)。

(2) 若随机变量 X 的分布律为

X	a_1	a_2	\dots	a_n
P_k	$1/n$	$1/n$	\dots	$1/n$

其中 $a_i \neq a_j, (i \neq j)$ ，则称 X 服从等可能分布。

(3) 若随机变量 X 的分布律为

$$P\{X = k\} = p(1-p)^{k-1}, \quad k = 1, 2, 3, \dots,$$

则称 X 服从参数为 p 的**几何分布** (Geometric Distribution)，记为 $X \sim G(p)$ 。

(4) 如果随机变量 X 服从以下分布律

$$P\{X = k\} = b(k; n, p) = C_n^k p^k (1-p)^{n-k},$$

其中 $0 < p < 1, 0 \leq k \leq n$ ，则称 X 服从参数为 n, p 的**二项分布** (Binomial Distribution)，记为 $X \sim B(n, p)$ 。

(5) 如果随机变量 X 服从以下分布律

$$P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, \dots$$

其中 $\lambda > 0$, 则称 X 服从参数为 λ 的泊松分布 (Poisson Distribution), 记为 $\mathbf{X} \sim P(\lambda)$.

Lecture 7: Continuous Random Variable

1. 设 X 是一个随机变量, x 是任意实数, 函数 $F(x) = P\{X \leq x\}$ 成为 X 的**分布函数** (Cumulative Distribution Function, CDF)。

2. 分布函数的主要性质:

- (1) $0 \leq F(x) \leq 1, x \in (-\infty, \infty)$;
- (2) $F(x_1) \leq F(x_2), (x_1 < x_2)$;
- (3) $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1$;
- (4) $\lim_{x \rightarrow x_0^+} F(x) = F(x_0), (-\infty < x_0 < \infty)$.

重要公式: $P\{a < X \leq b\} = F(b) - F(a), P\{X > a\} = 1 - F(a)$.

3. 定义: 如果对于随机变量 X 的分布函数 $F(x)$, 存在非负可积函数 $f(x)$, 使对于任意实数 x 有 $F\{X \leq x\} = \int_{-\infty}^x f(t)dt$, 则称 X 为**连续型随机变量**, 称 $f(x)$ 为 X 的**概率密度函数** (Probability Density Function), 记为 $X \sim f(x)$.

4. 概率密度的主要性质:

- (1) $f(x) \geq 0$;
- (2) $\int_{-\infty}^{+\infty} f(x)dx = 1$.

5. 常见连续型随机变量的分布:

(1) 若连续型随机变量 X 有概率密度

$$f(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{otherwise} \end{cases}, \quad (a < b)$$

则称 X 服从区间 (a, b) 上的**均匀分布** (Uniform Distribution), 记为 $X \sim U[a, b]$.

(2) 如果连续型随机变量 X 有以下概率密度

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & \text{otherwise} \end{cases},$$

其中 $\lambda > 0$, 则称 X 服从参数为 λ 的**指数分布** (Exponential Distribution), 记为 $\mathbf{X} \sim EP(\lambda)$.

其分布函数为

$$F(x) = \begin{cases} 1 - e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}.$$

(3) 如果连续型随机变量 X 有以下概率密度

$$\varphi_{\mu, \sigma^2}(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < +\infty$$

其中 μ, σ 为常数且 $\sigma > 0$, 则称 X 服从参数为 μ, σ 的**正态分布** (Normal Distribution) 或**高斯分布** (Gaussian Distribution), 简记为 $X \sim N(\mu, \sigma^2)$.

- 称 $N(0, 1)$ 为**标准正态分布**, 并将其概率密度函数 $\varphi_{0,1}(x)$ 简写为 $\varphi(x)$. 即有

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty < x < +\infty.$$

- 标准正态分布的概率密度函数 $\varphi(\cdot)$ 有以下性质:
 - (1) 无穷次可微;
 - (2) 偶函数;
 - (3) 在零点取得最大值;
 - (4) 有拐点 ± 1 ;
 - (5) 有水平渐近线 (x 轴).
- 引理: 若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$.
- 标准正态分布的分布函数的性质: $\Phi(-x) = 1 - \Phi(x)$.

Lecture 8: Derived Distribution: Single Random Variable

1. 设离散型随机变量 X 的概率分布为

$$P\{X = x_k\} = p_k, \quad k = 1, 2, \dots$$

令 $Y = g(X)$, 则 Y 也是一个离散型随机变量, 其分布可按如下步骤求得

- (1) 根据函数关系列出 Y 的所有可能值;
- (2) 对 Y 的每个可能值 y , $P\{Y = y\}$ 等于所有满足 $g(x_k) = y$ 的 p_k 之和.

2. 对连续型随机变量 X , 求 $Y = g(X)$ 的密度函数的基本方法是

- (1) 根据函数关系先求 Y 的分布函数

$$F_Y(y) = P\{Y \leq y\} = P\{g(X) \leq y\} = \int_{g(x) \leq y} f_X(x) dx$$

- (2) 然后对 $F_Y(y)$ 求导可得 Y 的概率密度.

3. 设随机变量 X 具有概率密度 $f_X(x)$, 其中 $-\infty < x < +\infty$, 又设函数 $g(x)$ 处处可导, 且恒有 $g'(x) > 0$ (或 $g'(x) < 0$), 则称 $Y = g(x)$ 是连续型随机变量, 其概率密度为

$$f_Y(y) = \begin{cases} f_X[h(y)]|h'(y)| & \alpha < y < \beta \\ 0 & \text{otherwise} \end{cases},$$

其中 $\alpha = \min(g(-\infty), g(+\infty))$, $\beta = \max(g(-\infty), g(+\infty))$, $h(y)$ 是 $g(x)$ 的反函数。

Lecture 9: Multiple Discrete Random Variable

1. 设 (X, Y) 为二维随机向量, 对于任意实数 x, y , 称二元函数

$$F(x, y) = P\{X \leq x, Y \leq y\}$$

为 (X, Y) 的联合分布函数 (Joint CDF)。

2. 联合分布函数的主要性质:

(1) $F(x, y)$ 对每个自变量都是广义单增的;

(2) $0 \leq F(x, y) \leq 1$

$$F(x, -\infty) = F(-\infty, y) = 0, \quad F(-\infty, -\infty) = 0, \quad F(+\infty, +\infty) = 1;$$

(3) $F(x, y) = F(x+0, y), \quad F(x, y) = F(x, y+0);$

(4) 随机向量 (X, Y) 落在矩形区域 $(x_1, x_2] \times (y_1, y_2]$ 内的概率为

$$\begin{aligned} &P\{x_1 < X \leq x_2, y_1 < Y \leq y_2\} \\ &= F(x_2, y_2) - F(x_2, y_1) - F(x_1, y_2) + F(x_1, y_1). \end{aligned}$$

3. 设二维离散型随机向量 (X, Y) 的所有可能取值为

$$(x_i, y_j), i = 1, 2, \dots, j = 1, 2, \dots$$

称

$$\begin{aligned} P\{X = x_i, Y = y_j\} &= p_{ij}, \\ i &= 1, 2, \dots, j = 1, 2, \dots \end{aligned}$$

为该随机向量的联合分布律。

二维离散型随机向量的联合分布律也可以用表格表示:

XY	y_1	y_2	\cdots	y_j	\cdots
x_1	p_{11}	p_{12}	\cdots	p_{1j}	\cdots
x_2	p_{21}	p_{22}	\cdots	p_{2j}	\cdots
\vdots	\vdots	\vdots		\vdots	
x_i	p_{i1}	p_{i2}	\cdots	p_{ij}	\cdots
\vdots	\vdots	\vdots		\vdots	

5. 设二维离散型随机向量 (X, Y) 的联合分布为

$$P\{X = x_i, Y = y_j\} = p_{ij},$$

$$i = 1, 2, \cdots, j = 1, 2, \cdots$$

则随机变量 X 的**边缘概率分布** (Marginal Probability Distribution) 为

$$p_{i\cdot} = P\{X = x_i\} = \sum_j p_{ij}, \quad i = 1, 2, \cdots$$

而随机变量 Y 的**边缘概率分布**为

$$p_{\cdot j} = P\{Y = y_j\} = \sum_i p_{ij}, \quad j = 1, 2, \cdots$$

通常将这两个分布分别写在联合分布表右边和下边.

当 $p_{\cdot j} > 0$ 时, 称

$$P\{X = x_i | Y = y_j\} = \frac{p_{ij}}{p_{\cdot j}} \quad i = 1, 2, \cdots$$

为 $Y = y_j$ 时 X 的**条件概率分布** (Conditional Probability Distribution).

当 $p_{i\cdot} > 0$ 时, 称

$$P\{Y = y_j | X = x_i\} = \frac{p_{ij}}{p_{i\cdot}} \quad j = 1, 2, \cdots$$

为 $X = x_i$ 时 Y 的**条件概率分布**.

6. 设随机向量 (X, Y) 的联合分布函数为 $F(x, y)$, 边缘分布函数分别为 $F_X(x)$ 和 $F_Y(y)$, 若对任意实数 x, y 有

$$F(x, y) = F_X(x) \cdot F_Y(y),$$

则称 X, Y **相互独立**. 若 (X, Y) 是离散型随机向量, X, Y 相互独立的充要条件为 $p_{ij} = p_{i\cdot} \cdot p_{\cdot j}$, $i, j = 1, 2, \dots$.

Lecture 10: Multiple Continuous Random Variable

1. 如果存在一个非负函数 $f(x, y)$, 使得二维随机向量 (X, Y) 的分布函数 $F(x, y)$ 可以写成

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv,$$

则称 (X, Y) 为二维连续型随机向量. 函数 $f(x, y)$ 称为 (X, Y) 的联合概率密度 (Joint PDF).

2. 联合概率密度函数的基本性质:

1. $f(x, y) \geq 0, \forall x, y$;
2. $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = F(\infty, \infty) = 1$;
3. 若函数 f 在点 (x, y) 处连续, 则有

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y).$$

4. 对任意的平面区域 D ,

$$P\{(X, Y) \in D\} = \iint_{(x, y) \in D} f(x, y) dx dy.$$

3. 设二维连续型随机向量 (X, Y) 的联合概率密度为 $f(x, y)$, 则 X, Y 的边缘概率密度分别定义为

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx.$$

此时 X, Y 的边缘分布函数分别为

$$F_X(x) = \int_{-\infty}^x f_X(u) du, \quad F_Y(y) = \int_{-\infty}^y f_Y(v) dv.$$

若 $f_Y(y) > 0$, 在 $Y = y$ 条件下, X 的条件概率密度定义为

$$f_{X|Y}(x|y) := \frac{f(x, y)}{f_Y(y)}.$$

同样地, 若 $f_X(x) > 0$ 时, 在 $X = x$ 条件下, Y 的**条件概率密度**定义为

$$f_{Y|X}(y|x) := \frac{f(x, y)}{f_X(x)}.$$

在 $Y = y$ 条件下, X 的**条件分布函数**定义为

$$\begin{aligned} F_{X|Y}(x|y) &= P\{X \leq x | Y = y\} \\ &= \lim_{h \rightarrow 0} P\{X \leq x | y \leq Y \leq y + h\} \end{aligned}$$

若 $f(\cdot, \cdot)$ 在点 (x, y) 处连续, $f_Y(\cdot)$ 在点 y 处连续, 且 $f_Y(y) > 0$, 则

$$F_{X|Y}(x|y) = \int_{-\infty}^x f_{X|Y}(s|y) ds.$$

在 $X = x$ 条件下 Y 的**条件分布函数**定义为

$$\begin{aligned} F_{Y|X}(y|x) &= P\{Y \leq y | X = x\} \\ &= \lim_{h \rightarrow 0} P\{Y \leq y | x \leq X \leq x + h\} \end{aligned}$$

若 $f(\cdot, \cdot)$ 在点 (x, y) 处连续, $f_X(\cdot)$ 在点 x 处连续, 且 $f_X(x) > 0$, 则

$$F_{Y|X}(y|x) = \int_{-\infty}^y f_{Y|X}(t|x) dt.$$

4. 设二维随机向量 (X, Y) 的联合分布函数为 $F(x, y)$, 边缘分布分别为 $F_X(x)$ 和 $F_Y(y)$, 若对任意实数 x, y 有

$$F(x, y) = F_X(x) \cdot F_Y(y),$$

则称 X, Y **相互独立**. 若 (X, Y) 是连续型随机向量, 则 X, Y 相互独立的充要条件为: 对所有实数 x, y , 有 $f(x, y) = f_X(x) \cdot f_Y(y)$ 。

5. 常用分布:

(1) 设 D 是平面上的有界区域, 其面积为 d , 若二维随机向量 (X, Y) 的概率密度为

$$f(x, y) = \begin{cases} 1/d, & (x, y) \in D; \\ 0, & \text{otherwise.} \end{cases}$$

则称 (X, Y) 服从 D 上的**均匀分布**.

若 (X, Y) 服从 D 上的均匀分布, 则 (X, Y) 落在某一区域 A 内的概率

$$\begin{aligned} P\{(X, Y) \in A\} &= \iint_A f(x, y) dx dy \\ &= \iint_{A \cap D} \frac{1}{d} dx dy \\ &= \frac{S}{d} \end{aligned}$$

其中 S 为 $A \cap D$ 的面积。

(2) 以下函数为密度的分布称为**二维正态分布**, 简记为 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$

$$\begin{aligned} f(x, y) &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \\ &\cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}, \end{aligned}$$

其中 μ_1, μ_2 为实数, $\sigma_1, \sigma_2 > 0$, $|\rho| < 1$.

设 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, X 和 Y 的边缘概率密度为 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$. 条件概率密度 $f_{Y|X}(y|x)$ 是一维正态分布, $X = x$ 时 Y 的条件分布为

$$N\left(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2)\right)$$

X 与 Y 相互独立的充要条件为 $\rho = 0$.

Lecture 11: Derived Distribution: Multiple Random Variable

1. 设离散型随机向量 (X, Y) 的联合分布为

$$P\{X = x_i, Y = y_j\} = p_{ij}, \quad i, j = 1, 2, \dots$$

令 $Z = g(X, Y)$, 则 Z 也是一个离散型随机变量, 其分布可按如下步骤求得

- (1) 根据函数关系列出 Z 的所有可能值;
- (2) 对 Z 的每个可能值 z , $P\{Z = z\}$ 等于所有满足 $g(x_i, y_j) = z$ 的 p_{ij} 之和.

2. 对连续型随机向量 (X, Y) , 求 $Z = g(X, Y)$ 的密度函数的基本方法是

- (1) 根据函数关系先求 Z 的分布函数

$$F_Z(z) = P\{Z \leq z\} = P\{g(X, Y) \leq z\}$$

- (2) 然后对 $F_Z(z)$ 求导可得 Z 的概率密度.

3. $Z = X + Y$

设连续型随机向量 (X, Y) 的联合密度函数为 $f(x, y)$, 则 $Z = X + Y$ 的概率密度为

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{+\infty} f(x, z-x) dx \\ &= \int_{-\infty}^{+\infty} f(z-y, y) dy. \end{aligned}$$

如果 X 与 Y 相互独立, 概率密度分别为 $f_X(x)$ 和 $f_Y(y)$, 则 $Z = X + Y$ 的概率密度为

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx \\ &= \int_{-\infty}^{+\infty} f_X(z-y) f_Y(y) dy. \end{aligned}$$

上述公式称为**卷积公式**.

3. 设 X 与 Y 相互独立, 均服从标准正态分布, 若 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, 且 X 与 Y 相互独立, 则

$$Z = X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

4. $Z = \max\{X, Y\}$, $Z = \min\{X, Y\}$

(相互独立) 设随机向量 X 与 Y 相互独立, 其分布函数分别为 $F_X(x)$ 和 $F_Y(y)$. 设 $Z = \max\{X, Y\}$ 的分布函数为 $F_{\max}(z)$, 则有

$$F_{\max}(z) = F_X(z) F_Y(z).$$

设 $Z = \min\{X, Y\}$ 的分布函数为 $F_{\min}(z)$, 则有

$$\begin{aligned} F_{\min}(z) &= F_X(z) + F_Y(z) - F_X(z) F_Y(z) \\ &= 1 - [1 - F_X(z)][1 - F_Y(z)]. \end{aligned}$$

(一般情况) 一般地, 设连续型随机向量 (X, Y) 的联合分布函数为 $F(x, y)$, 则 $U = \max\{X, Y\}$ 的分布为

$$F_U(u) = F(u, u).$$

设其边缘分布函数分别为 $F_X(x)$ 和 $F_Y(y)$, 则 $V = \min\{X, Y\}$ 的分布为

$$F_V(v) = F_X(v) + F_Y(v) - F(v, v).$$

$$\begin{aligned} F_V(v) &= P\{\min\{X, Y\} \leq v\} = P\{X \leq v \text{ 或 } Y \leq v\} \\ &= P\{X \leq v\} + P\{Y \leq v\} - P\{X \leq v, Y \leq v\} \\ &= F_X(v) + F_Y(v) - F(v, v) \end{aligned}$$

5. 高维随机向量

- 设 S 是某随机试验的样本空间, X_1, X_2, \dots, X_n 是该空间上的随机变量, 称

$$\vec{X} = (X_1, X_2, \dots, X_n)$$

为 S 上的或 n 维随机向量

- 设 $\vec{X} = (X_1, X_2, \dots, X_n)$ 为 n 维随机向量, 称 n 元函数

$$F(\vec{x}) = P\{X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n\}$$

为 \vec{X} 的联合分布函数, 其中

$$\vec{x} = (x_1, x_2, \dots, x_n).$$

- 设 $\vec{X} = (X_1, X_2, \dots, X_n)$ 为 n 维随机向量, 如果存在非负函数 $f(\vec{x})$, 使得对任意的 \vec{x} 有

$$F(\vec{x}) = \int_{-\infty}^{x_n} \cdots \int_{-\infty}^{x_2} \int_{-\infty}^{x_1} f(\vec{u}) du_1 du_2 \cdots du_n$$

则称 \vec{X} 为 n 维连续型随机向量, $f(\vec{x})$ 称为 \vec{X} 的概率密度函数

- 设 \vec{X} 的联合分布函数为 $F(\vec{x})$, 边缘分布分别为 $F_{X_i}(x_i), i = 1, 2, \dots, n$, 若对任意实数 x_1, x_2, \dots, x_n 有

$$F(\vec{x}) = F_{X_1}(x_1)F_{X_2}(x_2) \cdots F_{X_n}(x_n),$$

则称 X_1, X_2, \dots, X_n 相互独立。 X_1, X_2, \dots, X_n 相互独立的充要条件为: 对所有的实数 x_1, x_2, \dots, x_n , 有 $f(\vec{x}) = f_{X_1}(x_1) f_{X_2}(x_2) \cdots f_{X_n}(x_n)$ 。

6. n 维正态分布: 若 X_1, X_2, \dots, X_n 相互独立, 且

$$X_i \sim N(\mu_i, \sigma_i^2), \quad i = 1, 2, \dots, n$$

则对不全为零的数 a_1, a_2, \dots, a_n ,

$$a_1 X_1 + \cdots + a_n X_n \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right).$$

Lecture 12: Expectation and Variance

1. 设离散型随机变量 X 的分布律为 $P\{X = x_k\} = p_k, k = 1, 2, \dots$ 。若级数 $\sum_k x_k p_k$ 绝对收敛, 则称其和为随机变量 X 的数学期望 (Expectation), 记为 $E(X)$ 。

2. 设连续型随机变量 X 的概率密度为 $f(x)$, 若积分 $\int_{-\infty}^{+\infty} x f(x) dx$ 绝对收敛, 则称此积分为随机变量 X 的数学期望, 记为 $E(X)$ 。

3. 数学期望的性质: 设 X, X_1, X_2, \dots, X_n 为随机变量, C 为常数, 则有

$$(1) E(C) = C;$$

$$(2) E(CX) = CE(X), E(CX + D) = CE(X) + D;$$

$$(3) E(X_1 + X_2) = E(X_1) + E(X_2);$$

$$\text{推论: } E\left(\sum_{k=1}^n X_k\right) = \sum_{k=1}^n E(X_k).$$

(4) 若 X_1, X_2 是相互独立的随机变量, 则 $E(X_1 X_2) = E(X_1)E(X_2)$ 。

4. 设 X 为随机变量, $Y = g(X)$, 则

(1) 若 X 为离散型随机变量, 分布律为

$$P\{X = x_k\} = p_k, \quad k = 1, 2, \dots$$

则

$$E(Y) = \sum_k g(x_k) p_k.$$

(2) 若 X 为连续型随机变量, 概率密度为 $f(x)$, 则

$$E(Y) = \int_{-\infty}^{+\infty} g(x) f(x) dx.$$

5. 设 (X, Y) 为随机向量, $Z = g(X, Y)$, 则

(1) 若 (X, Y) 为离散型随机向量, 概率分布为

$$P\{X = x_i, Y = y_j\} = p_{ij}, \quad i, j = 1, 2, \dots$$

则

$$E(Z) = \sum_i \sum_j g(x_i, y_j) p_{ij}.$$

(2) 若 (X, Y) 为连续型随机向量, 概率密度为 $f(x, y)$, 则

$$E(Z) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy.$$

6. 设 X 是一随机变量, 若 $[X - E(X)]^2$ 的期望存在, 则称该期望为 X 的方差 (Variance), 记为 $Var(X)$ (或 $D(X)$), 即

$$Var(X) := E[X - E(X)]^2.$$

称 $\sqrt{Var(X)}$ 为 X 的标准差 (Standard Deviation), 记为 $\sigma(X)$ 。

方差的常用计算公式: $Var(X) = E(X^2) - [E(X)]^2$ 。

7. 设 X, Y 为随机变量, C 为常数, 则有

$$(1) Var(C) = 0$$

$$(2) Var(X + C) = Var(X)$$

$$(3) Var(CX) = C^2 Var(X) \implies Var(-X) = Var(X)$$

$$(4) Var(X + Y) = Var(X) + Var(Y) + 2E\{[X - E(X)][Y - E(Y)]\}.$$

若 X 和 Y 相互独立, 则有 $Var(X + Y) = Var(X) + Var(Y)$

性质 4 可以推广到多个相互独立的随机变量。

8. 常用概率分布的期望与方差

随机变量	X	$E(X)$	$Var(X)$
两点分布	$B(1, p)$	p	$p(1 - p)$
二项分布	$B(n, p)$	np	$np(1 - p)$
泊松分布	$P(\lambda)$	λ	λ
几何分布	$G(p)$	$1/p$	$(1 - p)/p^2$
均匀分布	$U[a, b]$	$(a + b)/2$	$(b - a)^2/12$
指数分布	$EP(\lambda)$	$1/\lambda$	$1/\lambda^2$
正态分布	$N(\mu, \sigma^2)$	μ	σ^2

9. 切比雪夫不等式: 设随机变量 X 具有数学期望 $E(X) = \mu$, 方差 $D(X) = \sigma^2$, 则对于任意正数 ϵ , 有不等式

$$P\{|X - \mu| \geq \epsilon\} \leq \frac{\sigma^2}{\epsilon^2}$$

Lecture 13: Covariance and Correlation Coefficient

1. 定义: 对于二维随机向量 (X, Y) , 称 $Cov(X, Y) := E[(X - EX)(Y - EY)]$ 为 X 与 Y 的协方差 (Covariance).

2. 设 X, Y, Z 为随机变量, a, b, c, d 为常数, 则有

$$(1) Cov(X, Y) = Cov(Y, X);$$

$$(2) Cov(aX + b, cY + d) = acCov(X, Y);$$

$$(3) Cov(X, Y + Z) = Cov(X, Y) + Cov(X, Z);$$

$$(4) Cov(X, Y) = E(XY) - E(X) \cdot E(Y);$$

(5) $Var(X \pm Y) = Var(X) + Var(Y) \pm 2Cov(X, Y)$. 推论: 两随机变量相互独立, 则协方差等于零; 反之未必成立.

3. 对于二维随机变量 (X, Y) , 如果两个变量的方差都不为零, 称

$$\rho_{X,Y} := \frac{Cov(X, Y)}{\sqrt{Var(X)} \cdot \sqrt{Var(Y)}}$$

为 X 与 Y 的相关系数 (Correlation Coefficient), 也可以记为 $\rho(X, Y)$.

4. 相关系数表示随机变量之间的线性相关程度:

$$1. |\rho_{X,Y}| \leq 1.$$

$$2. \rho_{X,Y} = -1 \text{ 当且仅当 } Y = aX + b, a < 0.$$

$$3. \rho_{X,Y} = 1 \text{ 当且仅当 } Y = aX + b, a > 0.$$

Lecture 14: Moments and Covariance Matrix

1. 定义：对随机变量 X 与正整数 k ,

1. 称 $E(X^k)$ 为 X 的 k 阶原点矩；

2. 称 $E[(X - EX)^k]$ 为 X 的 k 阶中心矩；

3. 称 $E(X^k Y^l)$ 为 X 和 Y 的 $k+l$ 阶混合矩；

4. 称 $E\{[(X - EX)^k][(Y - EY)^l]\}$ 为 X 和 Y 的 $k+l$ 阶混合矩。

*2. 定义：对二维随机向量 (X, Y) ，称矩阵

$$B = \begin{pmatrix} \text{Cov}(X, X) & \text{Cov}(X, Y) \\ \text{Cov}(Y, X) & \text{Cov}(Y, Y) \end{pmatrix}$$

为 (X, Y) 的协方差矩阵。

*3. 定义：设 $\vec{X} = (X_1, X_2, \dots, X_n)$ 为 n 维随机向量，称矩阵

$$B = (\text{Cov}(X_i, X_j))_{n \times n}$$

为 \vec{X} 的协方差矩阵。协方差阵为对称的半正定矩阵。

*4. 定义：以以下函数为密度的分布称为 n 元正态分布，简记为 $N(\vec{\mu}, B)$

$$\varphi(\vec{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} |B|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\vec{x} - \vec{\mu})^T B^{-1} (\vec{x} - \vec{\mu}) \right\},$$

其中 B 为 n 阶正定矩阵，

$$\vec{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad \vec{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{pmatrix}.$$

*5. n 元正态分布的性质：若 $\vec{X} \sim N(\vec{\mu}, B)$ ，则

- \vec{X} 的各分量的边缘分布为

$$X_i \sim N(\mu_i, b_{ii}), \quad i = 1, 2, \dots, n$$

其中 b_{ii} 为 B 的第 i 行第 i 列的元素;

- \vec{X} 的协方差矩阵为 B .

Lecture 15: Law of Large Number and Central Limit Theorem

1. 契比雪夫不等式：设随机变量 X 有期望和方差，则对于任给的 $\varepsilon > 0$ ，有

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{Var(X)}{\varepsilon^2},$$

即

$$P(|X - E(X)| < \varepsilon) \geq 1 - \frac{Var(X)}{\varepsilon^2}.$$

2. 弱大数定律（辛钦大数定律）：设 X_1, X_2, \dots, X_n 是相互独立，服从同一分布的随机变量序列，且具有数学期望 μ ，定义 Y_n 为前 n 个随机变量的算术平均，即

$$Y_n = \frac{1}{n} \sum_{i=1}^n X_i,$$

则对任意正数 ε ，有 $\lim_{n \rightarrow \infty} P\{|Y_n - \mu| < \varepsilon\} = 1$ 。

3. 伯努利大数定理：在独立实验序列中，记事件 A 发生的概率为 p 。以 $f_n(A)$ 表示前 n 次试验中事件 A 发生的次数，则对任意正数 ε ，

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{f_n(A)}{n} - p\right| < \varepsilon\right\} = 1.$$

4. 林德伯格—莱维定理（独立同分布的中心极限定理）：若 $\{X_n\}_{n \geq 1}$ 独立且同分布， $E(X_i) = \mu$ ， $Var(X_i) = \sigma^2 > 0$ ，令

$$Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma}$$

则其分布函数 $F_n(x)$ 收敛到 $\Phi(x)$ ，即对任何实数 x ，

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P\{Z_n \leq x\} = \Phi(x)$$

其中 $\Phi(x)$ 是标准正态分布 $N(0, 1)$ 的分布函数，

5. **李雅普诺夫定理**: 设随机变量序列 $\{X_n\}_{n \geq 1}$ 相互独立, $E(X_i) = \mu_i$, $Var(X_i) = \sigma_i^2 > 0$, 记 $B_n^2 = \sum_{i=1}^n \sigma_i^2$, 若存在正数 δ , 使得当 $n \rightarrow \infty$ 时,

$$\frac{1}{B_n^{2+\delta}} \sum_{i=1}^n E\{|X_i - \mu_i|^{2+\delta}\} \rightarrow 0,$$

随机变量之和的标准化变量

$$\mathbf{Z}_n = \frac{\sum_{i=1}^n X_i - \sum_{i=1}^n \mu_i}{B_n}$$

的分布函数 $F_n(x)$ 收敛到 $\Phi(x)$ 。

6. **棣莫弗—拉普拉斯定理**: 设随机变量 X 服从参数为 n, p 的二项分布, 即 $X \sim B(n, p)$, 则当 n 充分大时, X 近似服从正态分布, 即可以近似认为

$$\frac{X - np}{\sqrt{np(1-p)}} \sim N(0, 1).$$

Lecture 16: Sample and Sampling Distribution

1. 称随机变量 X_1, X_2, \dots, X_n 构成一个 (简单) 随机样本 (Random Sample), 如果这些随机变量相互独立且服从相同的分布。它们共同服从的分布称为**总体分布** (Population Distribution); 样本个数 n 称为**样本容量**。

2. 假设总体 X 服从**离散型**分布 $P\{X = x\} = p(x)$, 则 X_1, X_2, \dots, X_n 的联合分布律为

$$\begin{aligned} P\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\} \\ = p(x_1)p(x_2) \cdots p(x_n). \end{aligned}$$

3. 假设总体 X 服从**连续型**分布且密度函数为 $f(x)$, 则 X_1, X_2, \dots, X_n 的联合概率密度为

$$g(x_1, \dots, x_n) = f(x_1)f(x_2) \cdots f(x_n).$$

4. 设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, $g(X_1, X_2, \dots, X_n)$ 是 X_1, X_2, \dots, X_n 的函数, 若 g 中不含未知参数, 则称 $g(X_1, X_2, \dots, X_n)$ 是一个**统计量** (Statistic)。设 x_1, x_2, \dots, x_n 是相应于 X_1, X_2, \dots, X_n 的样本值, 则称 $g(x_1, x_2, \dots, x_n)$ 是 $g(X_1, X_2, \dots, X_n)$ 的**观察值**。

5. 常用统计量:

(1) 对样本 X_1, X_2, \dots, X_n , 称

$$\bar{X} := \frac{1}{n} \sum_{i=1}^n X_i = \frac{X_1 + X_2 + \cdots + X_n}{n}$$

为**样本均值**。

(2) 对样本 X_1, X_2, \dots, X_n , 称

$$S^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

为**样本方差**；称

$$S := \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

为**样本标准差**。

样本方差的性质：

$$S^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right).$$

(3) 对样本 X_1, X_2, \dots, X_n 及正整数 k ，称

$$A_k := \frac{1}{n} \sum_{i=1}^n X_i^k = \frac{X_1^k + X_2^k + \dots + X_n^k}{n}$$

为 k 阶**样本原点矩**；对 $k \geq 2$ ，称

$$M_k := \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

为 k 阶**样本中心矩**。

6. 总体分布函数 $F(x)$ 相对应的统计量称为**经验分布函数**。经验分布函数的做法如下：设 X_1, X_2, \dots, X_n 是总体 F 的一个样本，用 $S(x) (-\infty < x < \infty)$ 表示 X_1, X_2, \dots, X_n 中不大于 x 的随机变量个数，定义经验分布函数 $F_n(x)$ 为 $F_n(x) = \frac{1}{n} S(x)$, $(-\infty < x < \infty)$ 。

7. [中心极限定理的常用结论：**大量同分布随机变量的和、平均值近似服从正态分布**。] 设 X_1, X_2, \dots, X_n 是来自均值为 μ 、方差为 σ^2 的总体的简单样本，则当 n 充分大时，近似地有

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

8. 统计量的分布称为**抽样分布** (Sampling Distribution)。以下三个来自正态分布的抽样分布 χ^2 分布， t 分布， F 分布称为**统计学的三大分布**。

9. χ^2 分布

(1) 定义：设 X_1, X_2, \dots, X_n 相互独立，都服从标准正态分布，则

$$Y := \sum_{i=1}^n X_i^2 = X_1^2 + X_2^2 + \dots + X_n^2$$

称为服从 n 个自由度的 χ^2 分布，记为 $Y \sim \chi_n^2$ 或 $Y \sim \chi^2(n)$ 。

* n 个自由度的 χ^2 分布的概率密度函数为：

$$f(x) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0; \\ 0, & x \leq 0. \end{cases}$$

(2) χ^2 分布的性质：

1) 若 X 服从标准正态分布， $Y = X^2$ ，则 Y 服从 1 个自由度的 χ^2 分布，即

$$Y \sim \chi^2(1).$$

2) 可加性：设 $Y_1 \sim \chi^2(m)$, $Y_2 \sim \chi^2(n)$ ，且两者相互独立，则

$$Y_1 + Y_2 \sim \chi^2(m+n).$$

3) χ^2 分布的数字特征： $E(\chi^2(n)) = n$, $Var(\chi^2(n)) = 2n$ 。

(3) 对给定的 $\alpha \in (0, 1)$ ，称满足条件 $P\{\chi^2(n) > \chi_\alpha^2(n)\} = \alpha$ 的点 $\chi^2(n)(\alpha)$ 为 $\chi^2(n)$ 分布的上 α 分位点。

10. t 分布

(1) 定义：设两个随机变量 X, Y 相互独立，并且

$$X \sim N(0, 1), \quad Y \sim \chi^2(n).$$

则称

$$T := \frac{X}{\sqrt{Y/n}}$$

为服从 n 个自由度的 t 分布，记为 $T \sim t_n$ 或 $T \sim t(n)$ 。

* 具有 n 个自由度的 t 分布的概率密度函数为:

$$f(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \cdot \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}.$$

注: t 分布的概率密度函数为偶函数.

(2) 设 $T \sim t(n)$. 对给定的 $\alpha \in (0, 1)$, 称满足条件 $P\{T > t_\alpha(n)\} = \alpha$ 的点 $t_\alpha(n)$ 为 t_n 分布的上 α 分位点.

设 $Z \sim N(0, 1)$, 对给定的 $\alpha \in (0, 1)$, 称满足条件 $P\{Z > Z_\alpha\} = \alpha$ 的点 Z_α 为标准正态分布的上 α 分位点.

(3) 性质: $t_{1-\alpha}(n) = -t_\alpha(n)$, $Z_{1-\alpha} = -Z_\alpha$.

11. F 分布

(1) 定义: 设两个随机变量 Y_1, Y_2 相互独立, 并且

$$Y_1 \sim \chi^2(m), \quad Y_2 \sim \chi^2(n)$$

则

$$F := \frac{Y_1/m}{Y_2/n} \sim F(m, n).$$

称为自由度为 m 和 n 的 F 分布, 记为 $F \sim F_{m,n}$ 或 $F \sim F(m, n)$.

* 自由度为 m 和 n 的 F 分布的概率密度为:

$$f(x) = \begin{cases} \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right) \cdot \Gamma\left(\frac{n}{2}\right)} \left(\frac{m}{n}\right)^{\frac{m}{2}} x^{\frac{m}{2}-1} \left(1 + \frac{m}{n}x\right)^{-\frac{m+n}{2}}, & x > 0; \\ 0, & x \leq 0. \end{cases}$$

(2) F 分布的性质:

1) 若 $F \sim F(n, m)$, 则 $1/F \sim F(n, m)$.

2) 若 $T \sim t(n)$, 则 $T^2 \sim F(1, n)$.

(3) 设 $F \sim F(n, m)$. 对给定的 $\alpha \in (0, 1)$, 称满足条件

$$P\{F > F_\alpha(n, m)\} = \alpha$$

的点 $F_\alpha(n, m)$ 为 $F_{m,n}$ 分布的上 α 分位点. 性质: $F_{1-\alpha}(m, n) = \frac{1}{F_\alpha(n, m)}$.

12. 设 X_1, X_2, \dots, X_n 是取自正态总体 $N(\mu, \sigma^2)$ 的样本. 则 \bar{X} 与 S^2 相互独立, 且有

$$\begin{aligned} \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} &\sim N(0, 1), & \frac{\bar{X} - \mu}{S/\sqrt{n}} &\sim t(n-1), \\ \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} &\sim \chi^2(n), & \frac{(n-1)S^2}{\sigma^2} &\sim \chi^2(n-1). \end{aligned}$$

13. 设 X_1, X_2, \dots, X_m 与 Y_1, Y_2, \dots, Y_n 分别是取自两个相互独立的正态总体

$$N(\mu_1, \sigma_1^2), \quad N(\mu_2, \sigma_2^2)$$

的样本. 则

$$U := \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim N(0, 1),$$

其中 \bar{X}, \bar{Y} 分别是两个样本各自的均值.

14. 设 X_1, X_2, \dots, X_m 与 Y_1, Y_2, \dots, Y_n 分别是取自两个相互独立的正态总体

$$N(\mu_1, \sigma^2), \quad N(\mu_2, \sigma^2)$$

的样本. 则

$$T := \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{(m-1)S_1^2 + (n-1)S_2^2}{m+n-2} \cdot \left(\frac{1}{m} + \frac{1}{n}\right)}} \sim t_{m+n-2},$$

其中 $\bar{X}, \bar{Y}, S_1^2, S_2^2$ 分别是两个样本各自的均值及方差.

*15. 设 X_1, \dots, X_m 与 Y_1, \dots, Y_n 分别是取自两个相互独立的正态总体

$$N(\mu_1, \sigma_1^2), \quad N(\mu_2, \sigma_2^2)$$

的样本. 则

$$F := \frac{\sum_{i=1}^m (X_i - \mu_1)^2 / (m\sigma_1^2)}{\sum_{j=1}^n (Y_j - \mu_2)^2 / (n\sigma_2^2)} \sim F(m, n)$$

16. 设 X_1, \dots, X_m 与 Y_1, \dots, Y_n 分别是取自两个相互独立的正态总体

$$N(\mu_1, \sigma_1^2), \quad N(\mu_2, \sigma_2^2)$$

的样本. 则

$$F := \frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(m-1, n-1).$$

其中 S_1^2 和 S_2^2 分别是两个样本各自的方差.

Lecture 17: Point Estimation

1. 设总体 X 的分布函数形式已知，但它的一个或多个参数未知，借助于总体 X 的一个样本来估计总体未知参数的值的问题称为**点估计问题**。

2. 用样本矩来估计总体矩，用样本矩的连续函数来估计总体矩的连续函数，这种估计法称为**矩估计法** (Method of Moments)。具体方法：设总体分布中有 k 个待定参数 $\theta_1, \theta_2, \dots, \theta_k$ 。总体 X 的 m 阶原点矩为 $\theta_1, \theta_2, \dots, \theta_k$ 的函数，记为 $\alpha_m = \alpha_m(\theta_1, \theta_2, \dots, \theta_k)$ 。令总体的前 k 阶原点矩分别与同阶的样本原点矩相等，这样就得到了一个 k 元方程组

$$\begin{cases} \alpha_1(\theta_1, \theta_2, \dots, \theta_k) = A_1 \\ \alpha_2(\theta_1, \theta_2, \dots, \theta_k) = A_2 \\ \dots\dots\dots \\ \alpha_k(\theta_1, \theta_2, \dots, \theta_k) = A_k \end{cases}$$

记方程组的解为 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ ，用它们作为参数 $\theta_1, \theta_2, \dots, \theta_k$ 的估计量。

3. 设连续型（离散型）总体 X 的概率密度函数（概率函数）为

$$f(x; \theta_1, \theta_2, \dots, \theta_k).$$

则样本 X_1, X_2, \dots, X_n 在观测值 x_1, x_2, \dots, x_n 处的联合概率密度（概率）为

$$L(x_1, \dots, x_n; \theta_1, \dots, \theta_k) = \prod_{i=1}^n f(x_i; \theta_1, \dots, \theta_k).$$

将观测值 x_1, \dots, x_n 看成固定的，将 L 看做 $\theta_1, \dots, \theta_k$ 的函数，则该函数被称为**似然函数** (Likelihood Function)。如果似然函数

$$L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)$$

在

$$(\theta_1^*, \theta_2^*, \dots, \theta_k^*)$$

处达到最大值，则称上述参数为未知参数的**极大似然估计**。

(重点) 极大似然估计 (Maximum Likelihood Estimation) 的一般方法:

- (1) 写出似然函数 L ;
- (2) 求似然函数的对数 $\ln L$;
- (3) 对 $\ln L$ 求导 (偏导) 并令导数等于零, 得到似然方程组;
- (4) 解方程组得到 $\ln L$ 的驻点, 判断该驻点是否最大值点.

4. 假设 θ 为总体分布的参数, 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的一个估计. 如果对 θ 的一切可能取值, 都有 $E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 是 θ 的无偏估计 (unbiased estimator).

定理: 设总体 X 的期望和方差分别为

$$E(X) = \mu, \quad \text{Var}(X) = \sigma^2.$$

从总体取一组样本 X_1, X_2, \dots, X_n , 则样本均值 \bar{X} 与样本方差 S^2 分别是 μ 和 σ^2 的无偏估计, 即

$$E(\bar{X}) = \mu, \quad E(S^2) = \sigma^2.$$

5. 设 $\hat{\theta}$ 是参数 θ 的估计量, 称

$$MSE(\hat{\theta}) := E[(\hat{\theta} - \theta)^2]$$

为 $\hat{\theta}$ 的均方误差 (mean squared error)。

均方误差满足以下等式:

$$MSE(\hat{\theta}) = \text{Var}(\hat{\theta}) + [E(\hat{\theta}) - \theta]^2.$$

当 $\hat{\theta}$ 为 θ 的无偏估计量时, 有 $MSE(\hat{\theta}) = \text{Var}(\hat{\theta})$ 。

6. 估计量的比较: 在估计量的选取中,

- (1) 无偏估计量优于有偏估计量;
- (2) 在无偏估计量中, 方差越小的越好.

7. 若 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为参数 θ 的估计量, 若对于任意 $\theta \in$, 当 $n \rightarrow \infty$ 时, $\hat{\theta}(X_1, X_2, \dots, X_n)$ 依概率收敛于 θ , 则称 $\hat{\theta}$ 为 θ 的相合估计量。

Lecture 18: Interval Estimation

1. 设 θ 为总体的待估参数, 常数 $\alpha \in (0, 1)$, 若有两个统计量 $\hat{\theta}_1, \hat{\theta}_2$, 使得

$$P\{\hat{\theta}_1 < \theta < \hat{\theta}_2\} = 1 - \alpha.$$

则称 $(\hat{\theta}_1, \hat{\theta}_2)$ 为 θ 的置信系数为 $1 - \alpha$ 的置信区间. 对给定的置信系数 $1 - \alpha$, 根据样本观测值确定未知参数 θ 的置信区间 $(\hat{\theta}_1, \hat{\theta}_2)$, 称为对参数 θ 的区间估计.

2. 总体期望的区间估计 (正态总体、方差已知): 设 X_1, \dots, X_n 是取自正态总体 $N(\mu, \sigma^2)$ 的样本, 其中 σ^2 已知. 则总体期望 μ 的置信系数为 $1 - \alpha$ 的置信区间为

$$\left(\bar{X} - \frac{\sigma}{\sqrt{n}} \cdot Z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} \cdot Z_{\alpha/2} \right).$$

3. 总体期望的区间估计 (正态总体、方差未知): 设 X_1, \dots, X_n 是取自正态总体 $N(\mu, \sigma^2)$ 的样本, 其中 σ^2 未知. 则总体期望 μ 的置信系数为 $1 - \alpha$ 的置信区间为

$$\left(\bar{X} - \frac{S}{\sqrt{n}} \cdot t_{\frac{\alpha}{2}}(n-1), \bar{X} + \frac{S}{\sqrt{n}} \cdot t_{\frac{\alpha}{2}}(n-1) \right).$$

总体期望的置信水平为 $1 - \alpha$ 的单侧置信区间为 $\left(\bar{X} - \frac{S}{\sqrt{n}} \cdot t_{\alpha}(n-1), +\infty \right)$.

*4. 总体方差的区间估计 (正态总体、期望已知): 设 X_1, \dots, X_n 是取自正态总体 $N(\mu, \sigma^2)$ 的样本, 其中 μ 已知, 则总体方差 σ^2 的置信系数为 $1 - \alpha$ 的置信区间为

$$\left(\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha}^2(n)} \right).$$

*5. 总体方差的区间估计 (正态总体、期望未知): 设 X_1, \dots, X_n 是取自正态总体的样本, 则总体方差 σ^2 的置信系数为 $1 - \alpha$ 的置信区间为

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right).$$

注：总体标准差 σ 的置信区间为

$$\left(\sqrt{\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}}, \sqrt{\frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}} \right).$$

总体方差的置信水平为 $1 - \alpha$ 的单侧置信区间为： $\left(0, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right)$

*6. 两个正态总体的期望差的区间估计（两个正态总体，方差已知）：设两个总体的方差 σ_1^2 与 σ_2^2 均已知，则总体期望的差 $\mu_1 - \mu_2$ 的置信系数为 $1 - \alpha$ 的置信区间为

$$\left(\bar{X} - \bar{Y} - \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}} \cdot Z_{\alpha/2}, \bar{X} - \bar{Y} + \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}} \cdot Z_{\alpha/2} \right)$$

*7. 两个正态总体的期望差的区间估计（两个正态总体，方差未知，但相等）：设两个总体的方差未知，但知道它们相等，则总体期望的差 $\mu_1 - \mu_2$ 的置信系数为 $1 - \alpha$ 的置信区间为

$$\left(\bar{X} - \bar{Y} - S \cdot \sqrt{\frac{1}{m} + \frac{1}{n}} \cdot t_{\alpha/2}(m+n-2), \bar{X} - \bar{Y} + S \cdot \sqrt{\frac{1}{m} + \frac{1}{n}} \cdot t_{\alpha/2}(m+n-2) \right),$$

其中 $S = \sqrt{\frac{(m-1)S_1^2 + (n-1)S_2^2}{m+n-2}}$.

*8. 方差比的区间估计（两个正态总体，期望已知）：设两个总体的期望 μ_1 与 μ_2 已知，则两个总体的方差比 σ_1^2/σ_2^2 的置信系数为 $1 - \alpha$ 的置信区间为

$$\left(\frac{\sum_{i=1}^m (X_i - \mu_1)^2 / m}{F_{\alpha/2}(m, n) \sum_{j=1}^n (Y_j - \mu_1)^2 / n}, \frac{\sum_{i=1}^m (X_i - \mu_2)^2 / m}{F_{1-\alpha/2}(m, n) \sum_{j=1}^n (Y_j - \mu_2)^2 / n} \right).$$

*9. 方差比的区间估计（两个正态总体，期望未知）：设两个总体的期望 μ_1 与 μ_2 未知，则两个总体的方差比 σ_1^2/σ_2^2 的置信系数为 $1 - \alpha$ 的置信区间为

$$\left(\frac{S_1^2}{S_2^2 F_{\alpha/2}(m-1, n-1)}, \frac{S_1^2}{S_2^2 F_{1-\alpha/2}(m-1, n-1)} \right).$$

Lecture 19: Hypothesis Testing

1. 参数的假设检验主要用置信区间的方法，步骤如下：

- (1) 根据实际问题，提出原假设 H_0 与备择假设 H_1 ；
- (2) 假定 H_0 成立，选择分布已知的统计量；
- (3) 由给定的显著性水平 α ，计算统计量的临界值，由此划分拒绝域与接受域；
- (4) 根据样本观测值，计算统计量的观测值；
- (5) 检查观测值所在区域，并作出结论。
 - 如果落在拒绝域，则拒绝原假设 H_0
 - 如果落在接受域，则接受原假设 H_0

2. **第一类错误（弃真错误）**：原假设 H_0 符合实际情况，而检验结果把它否定了。 $P\{\text{reject } H_0 | H_0 \text{ is true}\} = \alpha$ 。**第二类错误（取伪错误）**：原假设 H_0 不符合实际情况，而检验结果把它肯定了。 $P\{\text{accept } H_0 | H_0 \text{ is false}\} = \beta$ 。

3. 单个正态总体，方差 σ^2 已知

条件	单个正态总体，方差 σ^2 已知		
原假设	$H_0 : \mu = \mu_0$		
备择假设	$\mu < \mu_0$	$\mu \neq \mu_0$	$\mu > \mu_0$
统计量	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$		
拒绝域	$Z \leq -Z_\alpha$	$ Z \geq Z_{\frac{\alpha}{2}}$	$Z \geq Z_\alpha$

4. 单个正态总体，方差 σ^2 未知

条件	单个正态总体，方差未知		
原假设	$H_0: \mu = \mu_0$		
备择假设	$\mu < \mu_0$	$\mu \neq \mu_0$	$\mu > \mu_0$
统计量	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}$		
拒绝域	$T \leq -t_{\alpha}(n-1)$	$ T \geq t_{\frac{\alpha}{2}}(n-1)$	$T \geq t_{\alpha}(n-1)$

5. 单个正态总体的方差

检验目标	单个正态总体的方差		
原假设	$H_0: \sigma^2 = \sigma_0^2$		
备择假设	$\sigma^2 < \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\sigma^2 > \sigma_0^2$
统计量	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$		
拒绝域	$\chi^2 \leq \chi_{1-\alpha}^2(n-1)$	$\chi^2 \geq \chi_{\frac{\alpha}{2}}^2(n-1)$ 或 $\chi^2 \leq \chi_{1-\frac{\alpha}{2}}^2(n-1)$	$\chi^2 \geq \chi_{\alpha}^2(n-1)$

*6. 两个正态总体，方差 σ_1^2, σ_2^2 已知

条件	两个正态总体，方差 σ_1^2, σ_2^2 已知		
原假设	$H_0: \mu_1 = \mu_2$		
备择假设	$\mu_1 < \mu_2$	$\mu_1 \neq \mu_2$	$\mu_1 > \mu_2$
统计量	$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\sigma_1^2/m + \sigma_2^2/n}} \sim N(0, 1)$		
拒绝域	$Z \leq -Z_{\alpha}$	$ Z \geq Z_{\frac{\alpha}{2}}$	$Z \geq Z_{\alpha}$

*7. 两个正态总体，方差未知但相等

条件	两个正态总体，方差未知但相等		
原假设	$H_0 : \mu_1 = \mu_2$		
备择假设	$\mu_1 < \mu_2$	$\mu_1 \neq \mu_2$	$\mu_1 > \mu_2$
统计量	$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{(m-1)S_1^2 + (n-1)S_2^2}{m+n-2} \cdot \sqrt{\frac{1}{m} + \frac{1}{n}}}}$		
拒绝域	$T \leq -t_\alpha(m+n-2)$	$ T \geq t_{\frac{\alpha}{2}}(m+n-2)$	$T \geq t_\alpha(m+n-2)$

*8. 两个正态总体的方差

检验目标	两个正态总体的方差		
原假设	$H_0 : \sigma_1^2 = \sigma_2^2$		
备择假设	$\sigma_1^2 < \sigma_2^2$	$\sigma_1^2 \neq \sigma_2^2$	$\sigma_1^2 > \sigma_2^2$
统计量	$F = \frac{S_1^2}{S_2^2} \sim F(m-1, n-1)$		
拒绝域	$F \leq F_{1-\alpha}(m-1, n-1)$	$F \geq F_{\frac{\alpha}{2}}(m-1, n-1)$ 或 $F \leq F_{1-\frac{\alpha}{2}}(m-1, n-1)$	$F \geq F_\alpha(m-1, n-1)$